Sweatshop no Codex: segunda leva

gpt-6-luna (max) no stage 2, gpt-6-sol (max) no stage 3

Foreman, sessão `sweatshop/2026-09-24-1855`

24 de setembro de 2026

Resumo

Segunda execução do `sweatshop-codex.ps1`, agora com o **sol em max** e a regra nova do stage 3 no `ticket-flow` (revisar contra os critérios escritos, todos os achados numa passada, requisito novo vira `CLEAN-*`; Agent-Skills `2c57db6`).

- **Produzido:** 4 tickets mergeados, **nenhuma reabertura**: SYN-011 (Copiáveis no PC), CLEAN-007, CLEAN-008 e CLEAN-009. Os dois últimos nasceram da revisão do SYN-011 e fecharam no mesmo run. PR de sessão: #6.
- **Custo:** 174 min de relógio (18:56–21:50), 38,0 M tokens de entrada (96,8 % em cache) e 345 k de saída (71 % raciocínio). **24 % da entrada** (9,2 M) foi gasta em estágios que não produziram nada.
- **Bug grave no driver, corrigido:** a sessão nova era igual à `main` e contava como mergeada. A revisão do SYN-011 não a viu, tomou a `main` como base e **mergeou o PR #5 direto na `main`**, sem passar pelo humano. Correção em Agent-Skills `8ba1ce1`.
- **Bloqueio que é seu:** SYN-012 precisa do Android SDK, que não existe nesta máquina. Ele segura os sete tickets Android.
- **Veredito provisório:** sol max com a regra nova resolveu o gargalo do run anterior (0 reaberturas em 4, contra 2 em 1). O luna segue correto e com TDD limpo. O desperdício agora está fora dos modelos: driver, tickets mal escritos e ambiente.

1 Linha do tempo

18:56	Lançamento. O driver cria `sweatshop/2026-09-24-1855` a partir da `main`, sem commits próprios. SYN-011, implementação (37 min).
19:33	Revisão do SYN-011 (13 min): **Approve**. Sem ver a sessão, abre e mergeia o PR #5 na `main`, fecha o ticket lá e cria CLEAN-008 e CLEAN-009. O driver lê o ticket na sessão, que não está `done`, e registra "reaberto".
19:46	Duas tentativas de stage 2 no SYN-011 (5 e 3 min) acham o ticket em `reviewing` na branch e param. SYN-011 fica `blocked` na sessão. O foreman acha a causa e corrige o driver às 19:58.
19:55	SYN-012, implementação (40 min): parser do QR e casca Android escritos, mas `blocked`: versão do Kotlin Gradle Plugin e falta do SDK.
20:35	CLEAN-007, implementação (4 min): `blocked`, o escopo de `lib.rs` não deixava tirar o `mod drag` que o critério 3 pedia.
20:39	Driver para, PR #6 com 0 tickets. O foreman traz a `main` para a sessão (SYN-011 `done`) e o fable high decide CLEAN-007 e metade do SYN-012; a outra metade (SDK) é escalada.
20:45	Relançamento. CLEAN-008 (7 + 10 min), CLEAN-007 (25 + 12 min, *Needs your call*) e CLEAN-009 (7 + 4 min), todos mergeados na primeira revisão.
21:50	"Nothing runnable". PR #6 com 4 tickets.

2 Métricas por estágio

Tokens do evento `turn.completed` do `codexexec--json`. "Cmds" é o número de itens `command_execution` concluídos (o Codex agrupa comandos; o número não é comparável com o do relatório anterior).

Estágio	Modelo	Min	Cmds	Entrada	Cache	Saída	Desfecho
SYN-011 impl.	luna	37	33	7,67 M	97,2 %	77,3 k	to-review
SYN-011 revisão	sol	13	72	5,57 M	98,1 %	21,7 k	merge na `main` (bug)
SYN-011 impl. 2–3	luna	8	25	0,58 M	85,7 %	17,4 k	leitura velha, blocked
SYN-012 impl.	luna	40	44	7,99 M	96,8 %	87,7 k	blocked (SDK)
CLEAN-007 impl. 1	luna	4	24	0,60 M	88,6 %	11,1 k	blocked (escopo)
CLEAN-008 impl.	luna	7	23	1,43 M	95,1 %	12,5 k	to-review
CLEAN-008 revisão	sol	10	35	1,72 M	96,5 %	9,1 k	mergeado
CLEAN-007 impl. 2	luna	25	44	6,18 M	97,2 %	65,3 k	to-review
CLEAN-007 revisão	sol	12	79	4,51 M	97,9 %	24,2 k	mergeado, Needs your call
CLEAN-009 impl.	luna	7	15	0,76 M	93,0 %	11,6 k	to-review
CLEAN-009 revisão	sol	4	35	1,01 M	94,8 %	7,0 k	mergeado
Total		167	429	38,02 M	96,8 %	344,9 k	
Perdido		52	93	9,17 M		116,2 k	4 estágios sem produto

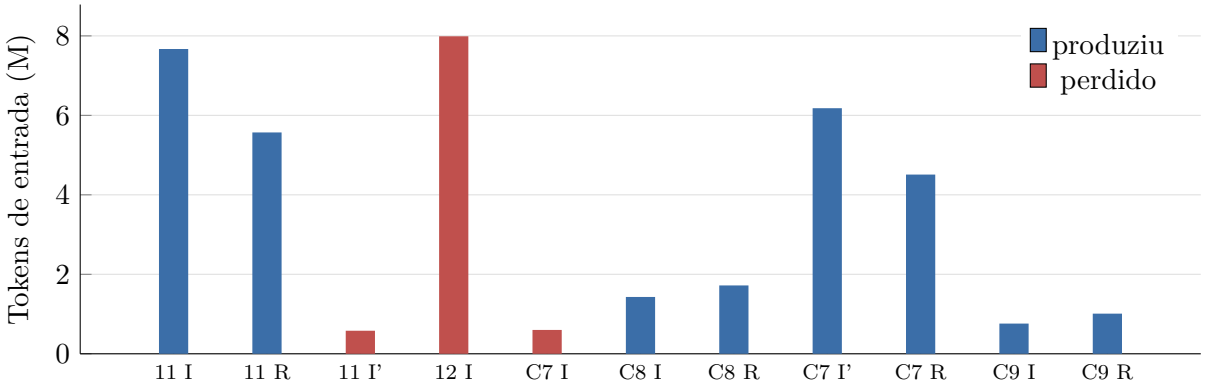

Onde foi o custo. Os 9,2 M perdidos têm três causas, nenhuma de modelo: o bug da sessão (SYN-011, 0,6 M e 8 min), a premissa falsa do SYN-012 (8,0 M e 40 min, o luna escreveu a casca inteira antes de descobrir que não podia compilá-la) e o deslize de escopo do CLEAN-007 (0,6 M e 4 min). Por ticket mergeado: SYN-011 13,2 M, CLEAN-007 10,7 M, CLEAN-008 3,2 M, CLEAN-009 1,8 M.

3 Comparação

Claude: os 13 tickets dos runs anteriores com Sonnet 5 e Opus 5.5 (`run-log.md`), sem contagem de tokens. Codex 1: SYN-010, sol high.

	Claude (13)	Codex 1 (1)	Codex 2 (4)
Minutos por ticket mergeado, mediana (faixa)	42 (7–89)	95	29 (11–50)
Tickets reabertos	5 de 13	1 de 1	0 de 4
Minutos por implementação que chegou a `to-review`, média	14,7	26,3	19,0
Minutos por revisão, média	9,2	5,3	9,8
Entrada por revisão (M)	—	0,7–2,3	1,0–5,6
Saída por revisão (k)	—	5,5–7,0	7,0–24,2

O sol max custa perto do dobro por revisão (tempo e tokens), mas uma reabertura no run anterior custava um ciclo de uns 20 min e 3–4 M. Ressalva forte: três dos quatro tickets são

`CLEAN-*` pequenos; só o SYN-011 é comparável ao SYN-010 em tamanho. Com $n = 4$ a tendência é boa, não conclusiva.

4 Observações sobre os modelos

gpt-6-luna (max), implementação

- **TDD limpo nos quatro tickets:** commit só de teste antes do código, e nenhum commit de código mexe em teste (conferido por `git show -stat`). A infração do run anterior não se repetiu.
- **Parou para perguntar quando devia:** CLEAN-007 e SYN-012 pararam com a pergunta certa, em vez de ampliar o escopo por conta própria. No SYN-012, porém, só descobriu o bloqueio depois de 40 min de código; checar o SDK antes de escrever teria custado 1 min.

gpt-6-sol (max), revisão

- **A regra nova funcionou:** a revisão do SYN-011 aprovou e mandou os dois achados fora dos critérios para CLEAN-008 (e-mail inválido) e CLEAN-009 (estado persistido no ADR), em vez de reabrir. Os dois fecharam no mesmo run, com 30 min somados.
- **Achados numa passada só:** nenhum ticket voltou ao stage 2.
- **Honesto sobre o que não verificou:** o CLEAN-007 saiu com *Needs your call* porque o critério 4 (verificação visual) não pôde ser feito, em vez de um Approve.

5 Integração com o Codex e o driver

- **Sessão igual à base conta como mergeada.** Tanto a busca do driver quanto a do `ticket-flow` usam `-no-merged`. No run anterior não apareceu porque commits de tentativa falha já tinham adiantado a sessão. Corrigido com um commit vazio na abertura (`8ba1ce1`). Efeito colateral: o SYN-011 está na `main` desde o PR #5, antes do PR de sessão.
- **Computer Use continua falhando** nas sessões do Codex: `SetIsBorderRequired failed: No such interface supported (0x80004002)`, e no SYN-011 também *coordinate input geometry is unavailable*. Acha a janela, não captura. Três tickets tentaram, nenhum conseguiu.
- **Branch do ticket some quando o estágio para para perguntar.** O driver apaga a branch criada na tentativa (`Reset-Tree -DropBranch`). Os dois commits do SYN-012 ficaram sem ref; o foreman os guardou na tag local `keep/syn-012` (`eb57837`).
- **Sem proxy no Codex.** Toda pergunta vira `blocked` e para o driver; o foreman responde pelo fable high e relança. Funcionou (duas decisões, uma escalada, 6 min entre parada e relançamento).
- **A política do Codex barra remoção recursiva** de pastas temporárias da inspeção; ficaram 40 MB em `%TEMP%\SynchroNice-CLEAN-007-review`, removidos pelo foreman.

6 Recomendações

1. **Manter sol max e a regra do stage 3.** Zero reaberturas pagam o dobro do custo por revisão. Reavaliar com um ticket largo.
2. **Decidir o Android SDK** (instalar aqui, mover o build para outra máquina ou CI, ou estacionar SYN-012). Sete tickets esperam isso.
3. **Consertar o Computer Use fora de um run**, ou tirar do `AGENTS.md` a nota de que ele funciona: hoje ela manda cada estágio tentar e falhar.
4. **Driver: não apagar a branch de um estágio que parou para perguntar com commits**; a tentativa seguinte deve continuar dela.

5. **Corrigir as premissas do stage 1:** `HANDOFF.md` item 3 e `spec.md:250` dizem que esta máquina tem SDK; é a outra.
6. Pendente do relatório anterior: **arquivo de parada** no driver.

7 Débito humano

- **Revisar o PR #5** (SYN-011), que entrou na `main` sem passar por você.
- SYN-011, critérios 4–8: inspeção ao vivo dos Copiáveis (destaque, clique, seleção, preferência de pontuação).
- SYN-010, via CLEAN-007: chat, painel, seletor nativo, tela inicial sem diálogo, menu da bandeja, e a engrenagem e o painel sobre a tela de QR e no chat.