Sweatshop no Claude: fechando os CLEAN

Sonnet 5 (xhigh) no stage 2, Opus 5.5 (xhigh) no stage 3

Foreman, sessão `sweatshop/2026-09-25-2127`

27 de setembro de 2026

Resumo

Terceiro dia da mesma sessão de sweatshop. Os dias 25 e 26 rodaram no Codex (SYN-012 a SYN-018 e CLEAN-010); este run voltou ao `sweatshop.ps1` do Claude para fechar os `CLEAN-*` que sobraram.

- **Produzido:** 7 tickets mergeados, com **uma reabertura** (CLEAN-012). CLEAN-011, 012 e 013 vieram da fila; CLEAN-014 e 015 nasceram da divisão do CLEAN-013 pelo proxy; CLEAN-016 e 017 nasceram dos dois *Needs your call* das revisões do CLEAN-013 e do CLEAN-014. Tracker vazio no fim. PR de sessão: #7, 15 tickets.
- **Custo: $59,99** a preço de lista em 24 estágios com preço (Sonnet $28,62, Opus $31,38), mais 2 estágios sem preço (os dois que estouraram o tempo). 346 min de estágio em 6 h 38 de relógio (11:01–17:39), 124,9 M tokens de entrada (96,8 % em cache) e 1,01 M de saída.
- **O que deu errado:** a **forma de chamar o gate**. O driver só libera `Bash(powershell:*)`; as sessões que tentaram a ferramenta PowerShell ou `powershell.exe` foram negadas em silêncio, e três estágios foram perdidos por isso (um deles com o conserto do CLEAN-015 ainda sem commit). Uma nota do foreman com o comando exato resolveu em todas as tentativas seguintes.
- **Veredito provisório:** Sonnet 5 xhigh + Opus 5.5 xhigh fecham tickets pequenos em 15–32 min e $3,7–8,1 cada. O CLEAN-013, largo demais (duas costuras), sozinho levou 171 min e $19,34 mais dois estágios sem preço, e só fechou depois de ser dividido três vezes.

1 Linha do tempo

11:01 Lançamento (aliases `sonnet`/`opus`, xhigh). CLEAN-012: implementação (25 min), revisão **reabre** (filtro do próprio provider contornável por `userId@`), nova implementação (10 min), mergeado às 11:54.

11:54 CLEAN-013, tentativa 1 (26 min): sai sem avançar o `Stage`. Tentativa 2 estoura os 45 min. `blocked`.

13:05 CLEAN-011 (14 + 17 min), mergeado. 13:37: "Nothing runnable", PR com 10 tickets.

13:37 Proxy divide o CLEAN-013: a prévia fora da main vira CLEAN-014. Relançamento recusado (`model has no version`); relançado com `sonnet-5`/`opus-5.5`.

13:59 CLEAN-013, tentativa 3, para e pergunta (`ReceivedFileRestartTest` fora dos Primary files). **Incidente do proxy**: às 14:05 ele roda `git` no repositório real e mistura código na branch `clean-013`; o CLEAN-014 para e pergunta. O foreman apaga a branch contaminada; o proxy decide (a) para o CLEAN-013.

14:15 CLEAN-013 falha em 2 min: gate negado. CLEAN-014 (8 + 10 min), mergeado às 14:33.

14:40 CLEAN-013, tentativa 4 (5 min), com a nota do comando exato do gate. A revisão (6 min) bloqueia no critério 1: presença do PC durante o download. O proxy reescreve o critério 1 e abre o CLEAN-015.

14:59 CLEAN-013, passada 2 (32 min). A revisão faz um conserto próprio, mergeia e **estoura os 20 min** antes de gravar o veredito.

15:55 CLEAN-015, tentativas 1 e 2 (4 + 9 min): gate negado; a 2 propõe usar `cargo` como gate. O conserto sem commit se perde no `Reset-Tree`; o vermelho fica preso em `refs/keep`.

16:06 Relançamento. CLEAN-013 revisado e fechado (15 min). CLEAN-015 retomado do vermelho (8 + 11 min), mergeado às 16:40.

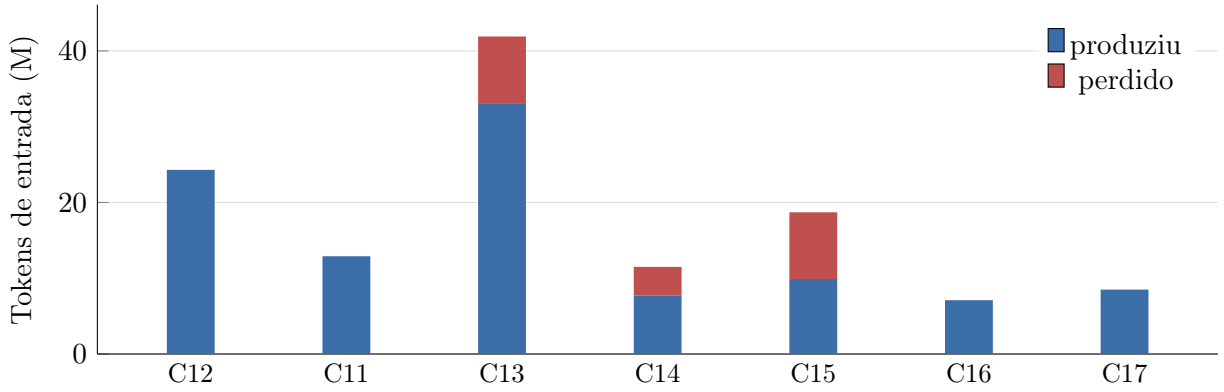
16:54 Proxy responde os dois *Needs your call*: CLEAN-016 e CLEAN-017. CLEAN-016, implementação (9 min). A revisão morre às 17:04 com o processo do Claude Code que hospedava o driver.

17:15 O único restart. CLEAN-016 (revisão 8 min) e CLEAN-017 (6 + 9 min), mergeados. 17:39: "Nothing runnable", PR com 15 tickets.

2 Métricas por estágio

Linhas de `.scratch/run-log.md` de 27/09. "?" é estágio morto por timeout, sem uso registrado. A revisão do CLEAN-016 morta às 17:04 não tem linha.

Estágio	Modelo	Min	Entrada	Cache	Saída	Custo	Desfecho
C12 impl.	sonnet	25	11,8 M	98 %	79 k	3,96	to-review
C12 revisão	opus	6	3,2 M	93 %	38 k	2,75	reaberto
C12 impl. 2	sonnet	10	4,3 M	98 %	37 k	1,59	to-review
C12 revisão 2	opus	12	5,0 M	96 %	48 k	3,19	mergeado
C13 impl. 1	sonnet	26	6,8 M	97 %	87 k	2,91	falhou
C13 impl. 2	sonnet	45	?	?	?	?	timeout
C11 impl.	sonnet	14	6,2 M	98 %	33 k	2,07	to-review
C11 revisão	opus	17	6,7 M	95 %	62 k	5,41	mergeado
C13 impl. 3	sonnet	20	6,5 M	97 %	70 k	2,63	perguntou (proxy)
C14 impl. 1	sonnet	9	3,8 M	97 %	29 k	1,43	perguntou (incidente)
C13 impl. 3b	sonnet	2	2,0 M	97 %	10 k	0,69	gate negado
C14 impl. 2	sonnet	8	3,2 M	97 %	19 k	1,14	to-review
C14 revisão	opus	10	4,5 M	95 %	37 k	3,04	mergeado
C13 impl. 4	sonnet	5	1,5 M	97 %	6 k	0,55	to-review
C13 revisão	opus	6	4,5 M	94 %	60 k	3,65	bloqueou (proxy)
C13 passada 2	sonnet	32	15,7 M	99 %	92 k	4,94	to-review
C13 revisão 2	opus	20	?	?	?	?	timeout após merge
C15 impl. 1	sonnet	4	2,3 M	97 %	18 k	0,90	gate negado
C15 impl. 2	sonnet	9	6,5 M	98 %	36 k	2,06	gate negado
C13 revisão 3	opus	15	4,9 M	94 %	67 k	3,97	mergeado
C15 impl. 3	sonnet	8	4,4 M	97 %	27 k	1,58	to-review
C15 revisão	opus	11	5,5 M	96 %	49 k	3,55	mergeado
C16 impl.	sonnet	9	3,5 M	98 %	19 k	1,18	to-review
C16 revisão	opus	8	3,6 M	95 %	34 k	2,50	mergeado
C17 impl.	sonnet	6	2,8 M	97 %	13 k	0,99	to-review
C17 revisão	opus	9	5,7 M	96 %	42 k	3,32	mergeado
Total		346	124,9 M	96,8 %	1012 k	59,99	
Perdido		115	21,4 M		250 k	7,99	7 estágios, 2 sem preço



Onde foi o custo. Por ticket: CLEAN-013 $19,34 (+2 estágios sem preço, 171 min), CLEAN-012 $11,48, CLEAN-015 $8,08, CLEAN-011 $7,48, CLEAN-014 $5,61, CLEAN-017 $4,31, CLEAN-016 $3,68. Os 21,4 M perdidos têm três causas, nenhuma de modelo no sentido estrito: o gate negado (CLEAN-013 3b, CLEAN-015 1–2: 10,8 M, $3,64), o ticket largo demais (CLEAN-013 1–2: 6,8 M e 71 min) e o incidente do proxy (CLEAN-014 1: 3,8 M). O Opus custou mais que o Sonnet ($31,38 contra $28,62) em menos da metade dos minutos.

3 Comparação

Mesma sessão, dias 25–26 no Codex (gpt-6-luna/gpt-6-sol, depois gpt-6-astra/gpt-5.6-sol), contra este run. Números de `run-log.md`.

	Codex, 25–26/09	Claude, 27/09
Estágios	65	26
Tickets mergeados	8	7
Minutos de estágio por ticket mergeado	86	49
Minutos por ticket, mediana	—	31 (15–171)
Reaberturas	16	1
Minutos por implementação que chegou a `to-review`, média	16,5	13,0
Minutos por revisão, média	6,5	11,4
Custo registrado	—	$59,99

Ressalva forte: os tickets do Codex eram SYN-* de funcionalidade (a casca Android, recepção, Compartilhar), maiores que os CLEAN-* de hoje; seis das 16 reaberturas foram do SYN-012 sozinho. A revisão do Opus é mais longa, mas refaz a prova vermelho-verde por mutação em todo ticket, o que as do Codex não faziam.

4 Atribuição das reaberturas

Uma reabertura no run: CLEAN-012, rodada 1, às 11:32. O revisor foi `opus` (Opus 5.5), o mesmo modelo do foreman; pela regra de não julgar a si mesmo, quem classificou foi o GPT-6 Astra (medium, read-only), sobre o ticket como estava no stage 2 (`4178923^`), o diff revisado (`4178923^..c2f1b4c`) e a revisão (`d9e5300`). Rótulos registrados como vieram, em `.scratch/reopen-attribution.md`.

Ticket	Rodada	Rótulo	Achado e porquê
CLEAN-012	1	S2-explícito/código	O filtro compara `uri.authority` cru e é contornado pelo prefixo `userId@`. O critério 2 exige barrar o FileProvider próprio, e o ContentResolver tira o prefixo.
CLEAN-012	1	S2-explícito/teste	O teste `SEND_MULTIPLE` leva só duas das três URIs. A lista de testes do ticket pedia "com as três".

Totais: 2 S2-explícito (1 código, 1 teste), 0 S2-implícito, 0 S1, 0 S3. Sem *drip-feeding* nem *churn* (primeira rodada). A reabertura é do implementador: os dois achados estavam escritos no ticket. Não discordo.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre os três repositórios desta máquina com `.scratch/run-log.md` (SynchroNice, SIGAA-ME, EasyMath), depois de registrar a atribuição acima. Cumulativo, não só deste run. É o primeiro relatório com scoreboard; não há anterior para comparar.

Implementador	Estágios	To review	Falhou	Perguntou	Mediana até review	Custo
fable	1	1	0	0	11m	?
gpt-6-luna	8	4	4	0	37m	?
gpt-6-sol	6	5	1	0	17m	?
gpt-5.6-sol	5	4	1	0	17m	?
gpt-6-astra	18	11	6	1	8m	?
sonnet	5	3	2	0	14m	$10.53 (4/5)
sonnet-5 xhigh	11	6	2	3	8m	$18.09 (11/11)
opus-5.5	7	4	0	3	14m	$15.12 (7/7)
gpt-6-luna max	10	6	1	3	23m	$0.60 (10/10)

Implementador	Revisor	Reviews	Reabertos	Taxa	Por S2	Taxa S2	Sem rótulo
fable	fable	1	1	100 %	0	≥0 %	1
?	opus	1	0	0 %	0	0 %	0
gpt-6-luna	gpt-6-sol	4	4	100 %	0	≥0 %	4
gpt-6-sol	gpt-5.6-sol	5	4	80 %	0	≥0 %	4
gpt-5.6-sol	gpt-6-astra	4	3	75 %	0	≥0 %	3
gpt-6-astra	gpt-5.6-sol	11	5	45 %	0	≥0 %	5
sonnet	opus	3	1	33 %	1	33 %	0
sonnet-5 xhigh	opus-5.5 xhigh	5	0	0 %	0	0 %	0
opus-5.5	opus-5.5	4	0	0 %	0	0 %	0
gpt-6-luna max	opus-5.5 high	6	0	0 %	0	0 %	0

Implementador → Revisor	Rodadas	S2 expl. código	S2 expl. teste	S2 implícito	S1	S3 ruído
sonnet → opus	1	1	1	0	0	0
fable → ?	4	5	1	3	1	0
sonnet → ?	10	3	6	9	3	2
opus → ?	1	3	0	0	0	0
sonnet? → ?	11	3	4	12	3	5

Como ler, para este run.

- **As linhas `sonnet` e `opus` deste run também eram xhigh.** O primeiro lançamento (11:01–13:37) passou os aliases, e o `run-log` gravou o modelo sem esforço. Pela regra, elas ficam separadas de `sonnet-5 xhigh`, embora sejam a mesma configuração. Somadas, seriam 8 revisões e 1 reabertura por S2.
- `sonnet-5 xhigh` → `opus-5.5 xhigh`**: 5 revisões, 0 reaberturas.** Abaixo de 10, é anedota. As duas revisões do CLEAN-013 que terminaram sem veredito não contam para ninguém.
- **Implementadores sob o mesmo revisor:** só há um par com Opus 5.5 xhigh revisando; a comparação com `gpt-6-luna max` passa por outro revisor (`opus-5.5 high`) e não vale direto.
- **Taxa S2 do `sonnet` sob `opus`: 33 %** (1 de 3), sem reabertura sem rótulo, então não é piso: é o número.

6 Observações sobre os modelos

Sonnet 5 (xhigh), implementação

- **TDD limpo:** as revisões conferiram commit só de teste antes do código em todos os tickets (CLEAN-013, 014, 015, 016, 017).
- **Obedece à nota do foreman:** com o comando exato do gate escrito no ticket, chegou a `to-review` na primeira tentativa em todos os casos (CLEAN-013 tentativa 4, CLEAN-015 retomado, 016, 017).
- **Sem a nota, improvisa:** tentou a ferramenta PowerShell, `powershell.exe` e `.\gate.ps1`, e no CLEAN-015 propôs rodar `cargo` como gate. Deixou o conserto sem commit antes de parar, e ele se perdeu.
- **Ticket largo trava:** no CLEAN-013 com duas costuras, gastou 71 min em duas tentativas sem chegar a `to-review`.

Opus 5.5 (xhigh), revisão

- **Uma reabertura em sete tickets,** e justa: o filtro do CLEAN-012 era contornável por `userId@`.
- **Achados de desenho viram decisão, não reabertura:** as corridas do CLEAN-013 (despacho) e do CLEAN-014 (prévia contra entrega) saíram como *Needs your call* com o conserto provável; viraram CLEAN-016 e 017 e fecharam no mesmo run, com $8 somados.
- **Desvio de processo:** a revisão das 15:31 escreveu teste e código no stage 3 (`d696148`, `92c4d62`) e mergeou antes de gravar o veredito; estourou os 20 min e custou uma revisão extra ($3,97).

7 Integração com o Claude e o driver

- **Gate só pela forma exata.** O `-allowedTools` libera `Bash(powershell:*)`; em `claude -p` as outras formas voltam "requires approval" sem diálogo. Três estágios perdidos; só nas duas tentativas do CLEAN-015 a própria sessão contou seis negações (`86803b6`).
- **A nota "o driver só aceita o alias" do `AGENTS.md` está invertida:** às 13:38 o driver recusou `sonnet`/`opus` com `model has no version`; ele exige `sonnet-5` e `opus-5.5`.
- `Reset-Tree` **descarta trabalho sem commit** (o conserto do CLEAN-015). O foreman passou a prender os vermelhos em `refs/keep/*`.
- **Preflight recusou** um relançamento às 14:58 porque o foreman deixou o repositório na branch de sessão depois de commitar.
- **O driver morre com o processo do Claude Code** que o lançou (17:04). O estado ficou limpo; o restart retomou pela revisão.
- **Proxy rodou `git` no repositório real** (14:05, commit com autor `t <t@t>`). Agora o proxy é o agente `~/.claude/agents/proxy.md` (Opus 5.5 xhigh), com a regra de só leitura na definição, e o `AGENTS.md` o nomeia em vez de fixar modelo.
- **O corpo do PR** ainda lista os *Needs your call* do CLEAN-013 e 014, já respondidos pelo proxy com CLEAN-016 e 017.

8 Recomendações

1. **Ampliar o `-allowedTools` do driver** para aceitar `Bash(powershell.exe:*)` e a ferramenta PowerShell no gate, ou escrever no `AGENTS.md` a forma exata e as proibidas. É a causa de toda a perda evitável do run.
2. **Corrigir a linha Models do `AGENTS.md`** para `stage 2 sonnet-5 xhigh, stage 3 opus-5.5 xhigh` e tirar a nota do alias.
3. **Stage 1 mais estreito:** um ticket, uma costura. O CLEAN-013 custou mais que três tickets pequenos juntos.
4. **Revisão grava o veredito antes do merge,** ou o limite de revisão sobe para 30 min quando o gate Android roda duas vezes.
5. **Driver: commit automático de "wip" antes do `Reset-Tree`** numa tentativa que parou para perguntar, para a seguinte retomar.
6. **Corpo do PR:** marcar como respondido o *Needs your call* seguido de `Proxy decided`.
7. **Manter `sonnet-5 xhigh` → `opus-5.5 xhigh`** e passar sempre o nome com versão, para o esforço entrar no log. Apoia-se nas linhas `sonnet-5 xhigh | opus-5.5 xhigh` (5 revisões, 0 reaberturas, anedota) e `sonnet | opus` (3 revisões, 1 por S2); reavaliar com 10 revisões no par.

9 Débito humano

- CLEAN-013: critério 1 contra o PC real — com um arquivo grande chegando, o chat do celular segue "Na rede" e um texto do PC aparece no meio do download (o teste prova contra um PC falso).
- CLEAN-013/015: celular real contra PC real — a janela do PC fica "presente" durante o download inteiro, texto do PC chega antes do fim da barra, e pausar o app no meio do download e voltar termina o arquivo.
- CLEAN-014: ANR ao abrir o app com muitas fotos Pendentes num celular real (o teste prova só que o construtor não decodifica).