# Sweatshop no Claude: fechando os CLEAN

Sonnet 5 (xhigh) no stage 2, Opus 5.5 (xhigh) no stage 3

Foreman, sessão `sweatshop/2026-09-25-2127`

27 de setembro de 2026

## Resumo

Terceiro dia da mesma sessão de sweatshop. Os dias 25 e 26 rodaram no Codex (SYN-012 a SYN-018 e CLEAN-010); este run voltou ao `sweatshop.ps1` do Claude para fechar os `CLEAN-*` que sobraram.

- **Produzido:** 7 tickets mergeados, com **uma reabertura** (CLEAN-012). CLEAN-011, 012 e 013 vieram da fila; CLEAN-014 e 015 nasceram da divisão do CLEAN-013 pelo proxy; CLEAN-016 e 017 nasceram dos dois *Needs your call* das revisões do CLEAN-013 e do CLEAN-014. Tracker vazio no fim. PR de sessão: #7, 15 tickets.
- **Custo: $59,99** a preço de lista em 24 estágios com preço (Sonnet $28,62, Opus $31,38), mais 2 estágios sem preço (os dois que estouraram o tempo). 346 min de estágio em 6 h 38 de relógio (11:01–17:39), 124,9 M tokens de entrada (96,8 % em cache) e 1,01 M de saída.
- **O que deu errado:** a **forma de chamar o gate**. O driver só libera `Bash(powershell:*)`; as sessões que tentaram a ferramenta PowerShell ou `powershell.exe` foram negadas em silêncio, e três estágios foram perdidos por isso (um deles com o conserto do CLEAN-015 ainda sem commit). Uma nota do foreman com o comando exato resolveu em todas as tentativas seguintes.
- **Veredito provisório:** Sonnet 5 xhigh + Opus 5.5 xhigh fecham tickets pequenos em 15–32 min e $3,7–8,1 cada. O CLEAN-013, largo demais (duas costuras), sozinho levou 171 min e $19,34 mais dois estágios sem preço, e só fechou depois de ser dividido três vezes.

# 1 Linha do tempo

11:01 Lançamento (aliases `sonnet`/`opus`, xhigh). CLEAN-012: implementação (25 min), revisão **reabre** (filtro do próprio provider contornável por `userId@`), nova implementação (10 min), mergeado às 11:54.

11:54 CLEAN-013, tentativa 1 (26 min): sai sem avançar o `Stage`. Tentativa 2 estoura os 45 min. `blocked`.

13:05 CLEAN-011 (14 + 17 min), mergeado. 13:37: "Nothing runnable", PR com 10 tickets.

13:37 Proxy divide o CLEAN-013: a prévia fora da main vira CLEAN-014. Relançamento recusado (`model has no version`); relançado com `sonnet-5`/`opus-5.5`.

13:59 CLEAN-013, tentativa 3, para e pergunta (`ReceivedFileRestartTest` fora dos Primary files). **Incidente do proxy**: às 14:05 ele roda `git` no repositório real e mistura código na branch `clean-013`; o CLEAN-014 para e pergunta. O foreman apaga a branch contaminada; o proxy decide (a) para o CLEAN-013.

14:15 CLEAN-013 falha em 2 min: gate negado. CLEAN-014 (8 + 10 min), mergeado às 14:33.

14:40 CLEAN-013, tentativa 4 (5 min), com a nota do comando exato do gate. A revisão (6 min) bloqueia no critério 1: presença do PC durante o download. O proxy reescreve o critério 1 e abre o CLEAN-015.

14:59 CLEAN-013, passada 2 (32 min). A revisão faz um conserto próprio, mergeia e **estoura os 20 min** antes de gravar o veredito.

15:55 CLEAN-015, tentativas 1 e 2 (4 + 9 min): gate negado; a 2 propõe usar `cargo` como gate. O conserto sem commit se perde no `Reset-Tree`; o vermelho fica preso em `refs/keep`.

16:06 Relançamento. CLEAN-013 revisado e fechado (15 min). CLEAN-015 retomado do vermelho (8 + 11 min), mergeado às 16:40.

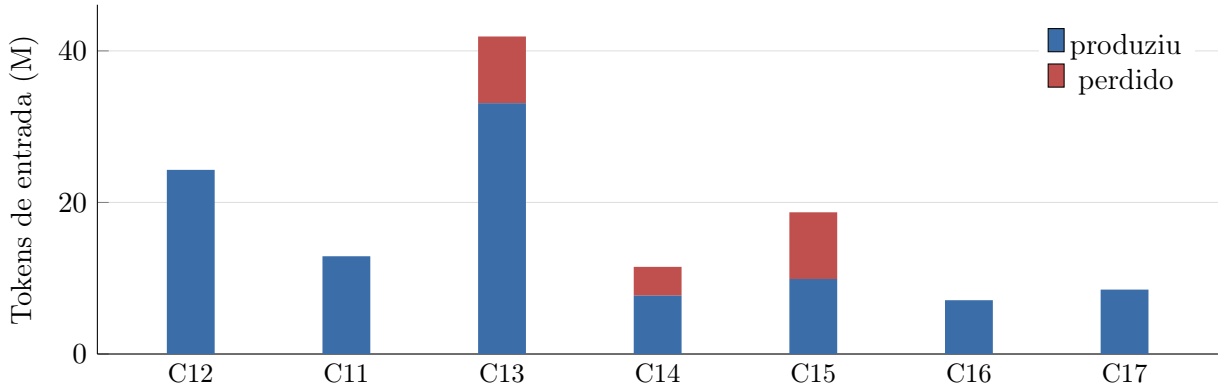
16:54 Proxy responde os dois *Needs your call*: CLEAN-016 e CLEAN-017. CLEAN-016, implementação (9 min). A revisão morre às 17:04 com o processo do Claude Code que hospedava o driver.

17:15 O único restart. CLEAN-016 (revisão 8 min) e CLEAN-017 (6 + 9 min), mergeados. 17:39: "Nothing runnable", PR com 15 tickets.

# 2 Métricas por estágio

Linhas de `.scratch/run-log.md` de 27/09. "?" é estágio morto por timeout, sem uso registrado. A revisão do CLEAN-016 morta às 17:04 não tem linha.

| Estágio | Modelo | Min | Entrada | Cache | Saída | Custo | Desfecho |
|---|---|---|---|---|---|---|---|
| C12 impl. | sonnet | 25 | 11,8 M | 98 % | 79 k | 3,96 | to-review |
| C12 revisão | opus | 6 | 3,2 M | 93 % | 38 k | 2,75 | reaberto |
| C12 impl. 2 | sonnet | 10 | 4,3 M | 98 % | 37 k | 1,59 | to-review |
| C12 revisão 2 | opus | 12 | 5,0 M | 96 % | 48 k | 3,19 | mergeado |
| C13 impl. 1 | sonnet | 26 | 6,8 M | 97 % | 87 k | 2,91 | falhou |
| C13 impl. 2 | sonnet | 45 | ? | ? | ? | ? | timeout |
| C11 impl. | sonnet | 14 | 6,2 M | 98 % | 33 k | 2,07 | to-review |
| C11 revisão | opus | 17 | 6,7 M | 95 % | 62 k | 5,41 | mergeado |
| C13 impl. 3 | sonnet | 20 | 6,5 M | 97 % | 70 k | 2,63 | perguntou (proxy) |
| C14 impl. 1 | sonnet | 9 | 3,8 M | 97 % | 29 k | 1,43 | perguntou (incidente) |
| C13 impl. 3b | sonnet | 2 | 2,0 M | 97 % | 10 k | 0,69 | gate negado |
| C14 impl. 2 | sonnet | 8 | 3,2 M | 97 % | 19 k | 1,14 | to-review |
| C14 revisão | opus | 10 | 4,5 M | 95 % | 37 k | 3,04 | mergeado |
| C13 impl. 4 | sonnet | 5 | 1,5 M | 97 % | 6 k | 0,55 | to-review |
| C13 revisão | opus | 6 | 4,5 M | 94 % | 60 k | 3,65 | bloqueou (proxy) |
| C13 passada 2 | sonnet | 32 | 15,7 M | 99 % | 92 k | 4,94 | to-review |
| C13 revisão 2 | opus | 20 | ? | ? | ? | ? | timeout após merge |
| C15 impl. 1 | sonnet | 4 | 2,3 M | 97 % | 18 k | 0,90 | gate negado |
| C15 impl. 2 | sonnet | 9 | 6,5 M | 98 % | 36 k | 2,06 | gate negado |
| C13 revisão 3 | opus | 15 | 4,9 M | 94 % | 67 k | 3,97 | mergeado |
| C15 impl. 3 | sonnet | 8 | 4,4 M | 97 % | 27 k | 1,58 | to-review |
| C15 revisão | opus | 11 | 5,5 M | 96 % | 49 k | 3,55 | mergeado |
| C16 impl. | sonnet | 9 | 3,5 M | 98 % | 19 k | 1,18 | to-review |
| C16 revisão | opus | 8 | 3,6 M | 95 % | 34 k | 2,50 | mergeado |
| C17 impl. | sonnet | 6 | 2,8 M | 97 % | 13 k | 0,99 | to-review |
| C17 revisão | opus | 9 | 5,7 M | 96 % | 42 k | 3,32 | mergeado |
| Total | | 346 | 124,9 M | 96,8 % | 1012 k | 59,99 | |
| Perdido | | 115 | 21,4 M | | 250 k | 7,99 | 7 estágios, 2 sem preço |




**Onde foi o custo.** Por ticket: CLEAN-013 $19,34 (+2 estágios sem preço, 171 min), CLEAN-012 $11,48, CLEAN-015 $8,08, CLEAN-011 $7,48, CLEAN-014 $5,61, CLEAN-017 $4,31, CLEAN-016 $3,68. Os 21,4 M perdidos têm três causas, nenhuma de modelo no sentido estrito: o gate negado (CLEAN-013 3b, CLEAN-015 1–2: 10,8 M, $3,64), o ticket largo demais (CLEAN-013 1–2: 6,8 M e 71 min) e o incidente do proxy (CLEAN-014 1: 3,8 M). O Opus custou mais que o Sonnet ($31,38 contra $28,62) em menos da metade dos minutos.

## 3 Comparação

Mesma sessão, dias 25–26 no Codex (gpt-6-luna/gpt-6-sol, depois gpt-6-astra/gpt-5.6-sol), contra este run. Números de `run-log.md`.

| | Codex, 25–26/09 | Claude, 27/09 |
|---|---|---|
| Estágios | 65 | 26 |
| Tickets mergeados | 8 | 7 |
| Minutos de estágio por ticket mergeado | 86 | 49 |
| Minutos por ticket, mediana | — | 31 (15–171) |
| Reaberturas | 16 | 1 |
| Minutos por implementação que chegou a `to-review`, média | 16,5 | 13,0 |
| Minutos por revisão, média | 6,5 | 11,4 |
| Custo registrado | — | $59,99 |

Ressalva forte: os tickets do Codex eram SYN-* de funcionalidade (a casca Android, recepção, Compartilhar), maiores que os CLEAN-* de hoje; seis das 16 reaberturas foram do SYN-012 sozinho. A revisão do Opus é mais longa, mas refaz a prova vermelho-verde por mutação em todo ticket, o que as do Codex não faziam.

# 4 Observações sobre os modelos

### Sonnet 5 (xhigh), implementação

- **TDD limpo:** as revisões conferiram commit só de teste antes do código em todos os tickets (CLEAN-013, 014, 015, 016, 017).
- **Obedece à nota do foreman:** com o comando exato do gate escrito no ticket, chegou a `to-review` na primeira tentativa em todos os casos (CLEAN-013 tentativa 4, CLEAN-015 retomado, 016, 017).
- **Sem a nota, improvisa:** tentou a ferramenta PowerShell, `powershell.exe` e `.\gate.ps1`, e no CLEAN-015 propôs rodar `cargo` como gate. Deixou o conserto sem commit antes de parar, e ele se perdeu.
- **Ticket largo trava:** no CLEAN-013 com duas costuras, gastou 71 min em duas tentativas sem chegar a `to-review`.

### Opus 5.5 (xhigh), revisão

- **Uma reabertura em sete tickets,** e justa: o filtro do CLEAN-012 era contornável por `userId@`.
- **Achados de desenho viram decisão, não reabertura:** as corridas do CLEAN-013 (despacho) e do CLEAN-014 (prévia contra entrega) saíram como *Needs your call* com o conserto provável; viraram CLEAN-016 e 017 e fecharam no mesmo run, com $8 somados.
- **Desvio de processo:** a revisão das 15:31 escreveu teste e código no stage 3 (`d696148`, `92c4d62`) e mergeou antes de gravar o veredito; estourou os 20 min e custou uma revisão extra ($3,97).

# 5 Integração com o Claude e o driver

- **Gate só pela forma exata.** O `-allowedTools` libera `Bash(powershell:*)`; em `claude -p` as outras formas voltam "requires approval" sem diálogo. Três estágios perdidos; só nas duas tentativas do CLEAN-015 a própria sessão contou seis negações (`86803b6`).
- **A nota "o driver só aceita o alias" do `AGENTS.md` está invertida:** às 13:38 o driver recusou `sonnet`/`opus` com `model has no version`; ele exige `sonnet-5` e `opus-5.5`.
- `Reset-Tree` **descarta trabalho sem commit** (o conserto do CLEAN-015). O foreman passou a prender os vermelhos em `refs/keep/*`.
- **Preflight recusou** um relançamento às 14:58 porque o foreman deixou o repositório na branch de sessão depois de commitar.
- **O driver morre com o processo do Claude Code** que o lançou (17:04). O estado ficou limpo; o restart retomou pela revisão.

- **Proxy rodou `git` no repositório real** (14:05, commit com autor `t <t@t>`). Agora o proxy é o agente `~/.claude/agents/proxy.md` (Opus 5.5 xhigh), com a regra de só leitura na definição, e o `AGENTS.md` o nomeia em vez de fixar modelo.
- **O corpo do PR** ainda lista os *Needs your call* do CLEAN-013 e 014, já respondidos pelo proxy com CLEAN-016 e 017.

## 6 Recomendações

1. **Ampliar o `-allowedTools` do driver** para aceitar `Bash(powershell.exe:*)` e a ferramenta PowerShell no gate, ou escrever no `AGENTS.md` a forma exata e as proibidas. É a causa de toda a perda evitável do run.
2. **Corrigir a linha Models do `AGENTS.md`** para `stage 2 sonnet-5 xhigh, stage 3 opus-5.5 xhigh` e tirar a nota do alias.
3. **Stage 1 mais estreito:** um ticket, uma costura. O CLEAN-013 custou mais que três tickets pequenos juntos.
4. **Revisão grava o veredito antes do merge,** ou o limite de revisão sobe para 30 min quando o gate Android roda duas vezes.
5. **Driver: commit automático de "wip" antes do `Reset-Tree`** numa tentativa que parou para perguntar, para a seguinte retomar.
6. **Corpo do PR:** marcar como respondido o *Needs your call* seguido de `Proxy decided`.

## 7 Débito humano

- CLEAN-013: critério 1 contra o PC real — com um arquivo grande chegando, o chat do celular segue "Na rede" e um texto do PC aparece no meio do download (o teste prova contra um PC falso).
- CLEAN-013/015: celular real contra PC real — a janela do PC fica "presente" durante o download inteiro, texto do PC chega antes do fim da barra, e pausar o app no meio do download e voltar termina o arquivo.
- CLEAN-014: ANR ao abrir o app com muitas fotos Pendentes num celular real (o teste prova só que o construtor não decodifica).