Sweatshop no Codex: o kit de QA

gpt-6.1-sol (high) no stage 2, gpt-6.1-sol (max) no stage 3

Foreman, sessão `sweatshop/2026-09-30-2146`

30 de setembro e 1º de outubro de 2026

Resumo

Primeiro run da fila `.scratch/qa/` (o kit de QA, SYN-022 a SYN-026), com a escalação pedida para este run só (`-Models`), sem mexer no binding. É o primeiro run do kit contra o celular real (Redmi, adb sem fio) e contra o emulador. O run teve três lançamentos: o driver caiu duas vezes pelo mesmo defeito, e o humano mandou relançar nas duas.

- **Produzido: os 5 tickets da fila mergeados** na sessão, todos *Approve*; SYN-026 com `Review: human` (mexe no `AGENTS.md`). SYN-024 foi reaberto três vezes antes de passar. A fila do kit está vazia; sobraram 6 abertos, todos fora do kit (`needs-triage`). PR de sessão: #8, 5 tickets.
- **Custo: $15,97** a preço de lista em 16 estágios com preço (high $8,81, max $7,17), mais 2 estágios sem preço (os dois que estouraram o tempo e derrubaram o driver). A revisão do SYN-022 saiu do `run-log` como "?" e foi recalculada pelo `.txt` ($0,57). 348 min de estágio em 349 min de relógio, em três janelas (21:46–00:08, 08:39–10:40, 15:31–16:57); 48,9 M tokens de entrada (96,3 % em cache) e 297 k de saída.
- **O que deu errado: processos órfãos do kit**. O `codex exec` não termina enquanto um filho que a sessão abriu (`pc.exe`, servidor `adb`, emulador) está vivo. Primeiro isso deixou o driver parado esperando (30 min no SYN-022). Depois, nos dois estágios que estouraram o limite, o `taskkill` não alcançou os órfãos, que seguravam o `.txt`, e o driver caiu num `ReadAllText` (00:08 e 10:40).
- **Veredito provisório:** barato e confiável no conteúdo: $0,87–1,46 por ticket pequeno, $4,2 o do emulador, $8,0 o SYN-024 com três reaberturas. A revisão em max é dura e reproduz cada achado; no SYN-024 ela entrou em casos cada vez mais raros do Wi-Fi. Os limites padrão (45/20 min) não servem para tickets que sobem emulador ou fazem QA no aparelho.

1 Linha do tempo

30/09, primeiro lançamento

21:46 Lançamento. O foreman desfez uma mudança só de fim de linha no `Cargo.toml` para o Preflight ver a árvore limpa.

21:46 SYN-022, implementação. A sessão termina às 21:59, mas o `codex exec` fica preso em `pc.exe` e `adb` órfãos até o foreman derrubá-los às 22:17.

22:17 SYN-022, revisão: zero achados, mergeado. A sessão termina às 22:25; o driver espera até os 20 min e mata o processo (custo "?").

22:37 SYN-023 (9 + 9 min), mergeado às 22:55; a revisão abre o CLEAN-018.

22:55 SYN-024, implementação (23 min). Por decisão do proxy, conserta a preparação opcional do kit (`6ad0599`): a negativa de `WRITE_SECURE_SETTINGS` vira aviso. O Redmi passa a barrar por PIN; o humano o destrava às 23:21.

23:19 SYN-024, revisão 1: **reabre** com quatro falhas e abre o CLEAN-019. 23:35: implementação 2 (13 min) corrige as quatro.

23:48 SYN-024, revisão 2. Às 23:49 o vigia do foreman derruba `pc.exe` e `adb` por engano (seção 7). A revisão faz QA real no Redmi e estoura os 20 min às 00:08. O driver cai em `ReadAllText`.

00:15 O foreman solta o arquivo, mas a permissão automática nega mover os não rastreados da `main`. Sem árvore limpa, sem relançamento.

01/10, segundo lançamento (pedido pelo humano)

08:39 Árvore limpa (não rastreados movidos para `.scratch/run-log/`), relançado com `-ReviewMinutes 40`.

08:40 SYN-024, revisão 2 refeita (14 min): três correções aprovadas, **reabre** pela recusa silenciosa do Wi-Fi. Implementação 3 (12 min).

09:07 SYN-024, revisão 3 (23 min): **reabre** porque `Wifi is disabled` sai também em `DISABLING`. Implementação 4 (9 min).

09:40 SYN-024, revisão 4 (14 min): zero achados, mergeado às 09:54.

09:55 SYN-025, implementação: ainda trabalhando (10 commits) quando estoura os 45 min às 10:40. O `adb` órfão segura o `.txt`; o driver cai de novo. O foreman renomeia a branch para `syn-025-timeout-20261001-1040` (guardada, não apagada).

01/10, terceiro lançamento (pedido pelo humano)

15:31 Relançado com `-ImplementMinutes 90 -ReviewMinutes 40`. SYN-025 recomeça do zero: 45 min até `to-review`; revisão 25 min, mergeado às 16:43. B.2 (QR pela câmera do emulador) fica manual.

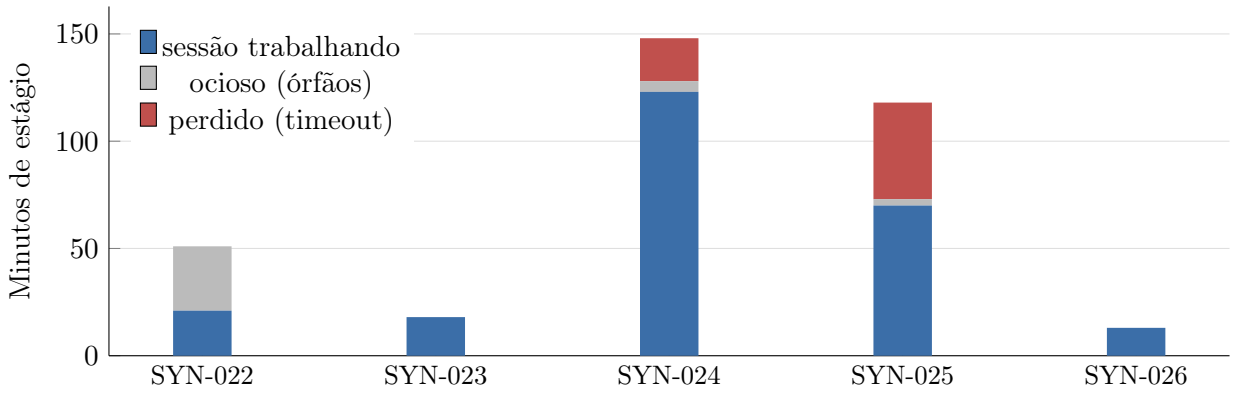
16:44 SYN-026 (5 + 8 min), mergeado às 16:57. "Nothing runnable", PR com 5 tickets.

2 Métricas por estágio

Linhas de `.scratch/run-log.md` do run. Os tokens foram recontados a partir do evento `turn.completed` de cada `.txt`. "Min" é o que o log grava; entre parênteses, os minutos até a sessão terminar, quando o processo ficou preso depois. Os dois estágios mortos no limite não têm linha: o driver caiu antes de gravá-las.

Estágio	Esforço	Min	Entrada	Cache	Saída	Custo	Desfecho
S22 impl.	high	31 (13)	2,34 M	96 %	20 k	0,84	to-review
S22 revisão	max	20 (8)	1,53 M	94 %	11 k	0,57*	mergeado
S23 impl.	high	9	2,43 M	97 %	12 k	0,76	to-review
S23 revisão	max	9	1,85 M	94 %	13 k	0,70	mergeado
S24 impl. 1	high	24 (23)	5,07 M	97 %	33 k	1,63	to-review
S24 revisão 1	max	16 (15)	2,41 M	94 %	23 k	0,96	reaberto
S24 impl. 2	high	13	2,28 M	96 %	15 k	0,77	to-review
S24 revisão 2a	max	20	?	?	?	?	timeout, driver caiu
S24 revisão 2	max	15 (14)	2,69 M	95 %	17 k	0,97	reaberto
S24 impl. 3	high	12	3,27 M	97 %	13 k	0,97	to-review
S24 revisão 3	max	24 (23)	3,81 M	96 %	24 k	1,25	reaberto
S24 impl. 4	high	9	1,96 M	96 %	9 k	0,63	to-review
S24 revisão 4	max	15 (14)	2,32 M	95 %	14 k	0,83	mergeado
S25 impl. a	high	45	?	?	?	?	timeout, driver caiu
S25 impl.	high	47 (45)	10,23 M	98 %	48 k	2,83	to-review
S25 revisão	max	26 (25)	4,30 M	97 %	28 k	1,39	mergeado
S26 impl.	high	5	1,13 M	95 %	4 k	0,38	to-review
S26 revisão	max	8	1,26 M	94 %	10 k	0,49	mergeado
Total		348	48,85 M	96,3 %	297 k	15,97	
Ocioso		37					esperando órfãos
Perdido		65	?		?	?	2 estágios sem preço

*O log grava "?" (processo morto no limite); recalculado pelo `.txt` com a tabela de preços do driver.



Onde foi o custo. Por ticket: SYN-024 $8,01 (mais 1 estágio sem preço), SYN-025 $4,22 (mais 1 sem preço, 45 min), SYN-023 $1,46, SYN-022 $1,41, SYN-026 $0,87. O SYN-024 sozinho é metade do run: quatro revisões e quatro implementações, quase tudo no Wi-Fi fora. O desperdício foi de tempo, não de dólar: 37 min de driver parado esperando processos que já tinham terminado (30 deles antes de o vigia automático existir) e 65 min em dois estágios mortos no limite, um deles com trabalho real de 10 commits guardado na branch `syn-025-timeout-20261001-1040`.

3 Comparação

Números de `run-log.md`. O run de 27/09 é o do relatório `2026-09-27-sweatshop-claude.pdf`.

	Claude, 27/09	Codex gpt-6.1-sol, 30/09–01/10
Estágios	26	18 (16 no log)
Tickets mergeados	7	5
Minutos de estágio por ticket mergeado	49	70
Minutos por ticket, mediana	31 (15–171)	51 (13–148)
Custo por ticket mergeado	$3,68–19,34	$0,87–8,01
Reaberturas	1	3 (todas no SYN-024)
Minutos por implementação até `to-review`, média	13,0	16,4
Minutos por revisão concluída, média	11,4	14,5
Custo registrado	$59,99	$15,97

Ressalva forte: os tickets são de outro tipo. Os CLEAN de 27/09 mexiam no app com testes unitários; os SYN do kit escrevem scripts PowerShell e Node, sobem emulador e tentam o celular real. A ociosidade e os timeouts pesam nos minutos deste run e não existiam no de 27/09. O custo é quase um quarto.

4 Atribuição das reaberturas

Três reaberturas no run, todas do SYN-024 (rodadas 1, 2 e 3 do ticket no log). O revisor foi `gpt-6.1-sol max`, que não é o modelo do foreman (Opus 5.5), então o foreman classificou. Evidência por rodada: o ticket no stage 2 (`fc384a2`, `3cd1413`, `5e8223a`), o diff revisado e a revisão (`9ca8337`, `3eba2c9`, `4f01824`). Linhas em `.scratch/reopen-attribution.md`.

Rodada	Rótulo	Achado e porquê
1	S2-explícito/código	`wifi-off` ignora o erro do `nohup` e sai 0 com `reconnected=true` quando `CHANGE_WIFI_STATE` é negado. O critério 9 diz que falha da ação pedida é fatal.
1	S2-explícito/código ?	Com console 850, `prévia.txt` vira mojibake e `track` aceita o arquivo anterior. A lista de testes pede a recusa; o acento é o mesmo critério num nome comum.
1	S2-implícito	Upload interrompido deixa o arquivo com `hash=null` e a limpeza o recusa para sempre: caminho de falha do código novo.
1	S2-implícito	A normalização transforma `C:\` em `C:` e os guards recusam a Pasta na raiz, que o app permite.
2	S2-explícito/código ?	O kit confia no código de saída do `svc`, que o AOSP devolve 0 mesmo com recusa silenciosa. Critérios 4 e 9; o ? é porque pede saber que o `svc` ignora o retorno.
3	S2-implícito ?	A confirmação aceita `Wifi is disabled`, que sai também em `DISABLING`; com atraso maior que N a rede não cai. Código novo da rodada 3; o revisor não afirma o atraso no Redmi.

Totais: 3 S2-explícito (3 código, 0 teste), 3 S2-implícito, 0 S1, 0 S3. As três reaberturas são do implementador.

O que é do stage 3. *Drip-feeding* na rodada 2: a recusa silenciosa já existia no código da rodada 1, e a própria revisão 2 escreve que foi "miss daquela passada". Sem *churn* estrito: a rodada 3 é um defeito do jeito como o implementador seguiu o conselho certo da rodada 2 (conferir o estado), não do conselho. Mas a sequência mostra o padrão a vigiar: cada revisão desce um nível no Wi-Fi (código de saída, recusa silenciosa, estado intermediário com IWLAN), num kit de QA cujo critério 4 ainda está como débito humano no aparelho real.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre os quatro repositórios desta máquina com `.scratch/run-log.md` (SynchroNice, SIGAA-ME, EasyMath, PhysiSyst), depois de registrar a

atribuição acima. Cumulativo.

Implementador	Estágios	To review	Falhou	Perguntou	Mediana até review	Custo
fable	1	1	0	0	11m	?
gpt-6-luna	8	4	4	0	37m	?
gpt-6-sol	6	5	1	0	17m	?
gpt-5.6-sol	5	4	1	0	17m	?
gpt-6-astra	18	11	6	1	8m	?
sonnet	5	3	2	0	14m	$10.53 (4/5)
sonnet-5 xhigh	11	6	2	3	8m	$18.09 (11/11)
gpt-6.1-sol high	33	29	0	4	7m	$21.39 (33/33)
opus-5.5	7	4	0	3	14m	$15.12 (7/7)
gpt-6-luna max	89	61	10	18	17m	$4.91 (85/89)
sonnet-5.5 high	2	2	0	0	7m	$3.77 (2/2)

Implementador	Revisor	Reviews	Reabertos	Taxa	Por S2	Taxa S2	Sem rótulo
fable	fable	1	1	100 %	0	≥0 %	1
?	opus	1	0	0 %	0	0 %	0
gpt-6-luna	gpt-6-sol	4	4	100 %	0	≥0 %	4
gpt-6-sol	gpt-5.6-sol	5	4	80 %	0	≥0 %	4
gpt-5.6-sol	gpt-6-astra	4	3	75 %	0	≥0 %	3
gpt-6-astra	gpt-5.6-sol	11	5	45 %	0	≥0 %	5
sonnet	opus	3	1	33 %	1	33 %	0
sonnet-5 xhigh	opus-5.5 xhigh	5	0	0 %	0	0 %	0
gpt-6.1-sol high	gpt-6.1-sol max	29	8	28 %	7	24 %	0
opus-5.5	opus-5.5	4	0	0 %	0	0 %	0
gpt-6-luna max	opus-5.5 high	18	1	6 %	1	6 %	0
gpt-6-luna max	gpt-6-sol max	43	23	53 %	22	51 %	0
?	gpt-6-sol max	1	0	0 %	0	0 %	0
sonnet-5.5 high	gpt-6-sol max	2	1	50 %	1	50 %	0

Implementador → Revisor	Rodadas	S2 expl. código	S2 expl. teste	S2 implícito	S1	S3 ruído
sonnet → opus	1	1	1	0	0	0
gpt-6.1-sol high → gpt-6.1-sol max	8	3	0	9	1	0
fable → ?	4	5	1	3	1	0
sonnet → ?	10	3	6	9	3	2
opus → ?	1	3	0	0	0	0
sonnet? → ?	11	3	4	12	3	5
gpt-6-luna max → opus-5.5 high	1	1	1	0	1	0
gpt-6-luna max → gpt-6-sol max	23	31	3	23	12	15
sonnet-5.5 high → gpt-6-sol max	1	3	0	2	0	0

O que mudou desde o relatório de 27/09.

- **Linhas novas:** `gpt-6.1-sol high` (33 estágios, 29 em `to-review`, nenhum falho, 7 min de mediana) e o par `gpt-6.1-sol high` → `gpt-6.1-sol max`: 29 revisões, 28 % de reabertura, **taxa S2 24 %**, sem reabertura sem rótulo, então não é piso. Este run soma 8 revisões e 3 reaberturas; o resto vem do PhysiSyst. Também são novas `sonnet-5.5 high` e os pares com `gpt-6-sol max` revisando.
- **Cresceu:** `gpt-6-luna max`, de 10 para 89 estágios, em outros repositórios.
- **Mesma implementação, revisores diferentes** (os dois pares com mais de 10 revisões): `gpt-6-luna max` reabre 6 % sob `opus-5.5 high` (18) e 53 % sob `gpt-6-sol max` (43), com S2 em 51 %. A diferença é do revisor, não do implementador.
- **Implementadores sob o mesmo revisor:** ninguém além do próprio `gpt-6.1-sol high` foi revisado por `gpt-6.1-sol max`. A linha não compara implementadores; só diz que o par, nos tickets em que rodou, reabre um em cada quatro por culpa do implementador.

6 Observações sobre os modelos

gpt-6.1-sol (high), implementação

- **TDD limpo em todos os tickets de código:** commit de teste antes do código em cada rodada, prova vermelha registrada no ticket. As revisões a reproduziram contra as versões anteriores.
- **Pede ao proxy em vez de travar:** no SYN-022 e no SYN-024 a sessão chamou o agente `proxy` pelo Claude CLI (só leitura) e seguiu com a decisão registrada. Nenhum `blocked`.
- **Conserta o pedido, não a classe:** no Wi-Fi, cada rodada fechou exatamente o caso apontado (código de saída, depois o estado), e a revisão seguinte achou o vizinho. Três dos seis achados são S2-implícito.
- **Deixa processos abertos** (`pc.exe`, servidor `adb`, emulador) ao terminar. É a causa da ociosidade e dos dois crashes.

gpt-6.1-sol (max), revisão

- **Reproduz antes de reabrir:** todos os achados vieram com repro (adb falso, console 850, Pasta temporária, fonte AOSP) e linha de código, e a prova vermelho-verde dos commits originais foi refeita.
- **Separa achado de critério:** o que não tinha critério virou ticket (CLEAN-018, CLEAN-019), não motivo de reabertura.
- **Desce um nível por rodada no mesmo eixo:** as revisões 2 e 3 do SYN-024 acharam casos que já estavam ao alcance da revisão anterior (a 2 admite isso).
- **Lenta com aparelho e emulador:** 23–25 min nas revisões que fazem QA real; com 20 min de limite, a revisão 2 original morreu.

7 Integração com o Codex e o driver

- `codex exec` **não sai com filhos vivos.** O driver faz `WaitForExit` no processo; um `pc.exe`, servidor `adb` ou emulador aberto pela sessão o segura até alguém matá-lo ou o limite estourar. Aconteceu em quase todo estágio que tocou o aparelho, o app ou o emulador.
- `taskkill /T` **não alcança os órfãos:** o pai deles já morreu, então a árvore não os inclui, e eles seguem segurando o `stdout` redirecionado para o `.txt`.
- `ReadAllText` **sem tolerância a lock:** o arquivo preso derrubou o driver duas vezes (00:08 e 10:40), sempre depois de um timeout, e o estágio ficou sem linha no log.
- **Árvore suja na** `main` **depois do run:** `qa/node_modules` e os artefatos de `.scratch/qa-runs/` são ignorados na sessão, mas a `main` não tem esse `.gitignore`. Cada fim de run deixa a `main` suja e o Preflight recusa o relançamento. Some quando o PR #8 for mergeado.
- **Run paralelo:** um sweatshop do PhysiSyst rodava ao mesmo tempo. Ele não usa `adb`; matar o servidor não o afetou.
- **O vigia do foreman.** Desde 23:39, um monitor matava `pc.exe` e `adb` (e, no terceiro lançamento, o emulador) quando o driver seguia parado 60 s depois de um `.final`. Às 23:49 ele mediu tarde, com o driver já na revisão seguinte, e matou os dois no começo da revisão 2 do SYN-024; a revisão os reabriu e pode ter perdido minutos. Corrigido às 23:50 para só agir quando a última linha do driver ainda é o lançamento daquele estágio. Depois disso agiu certo seis vezes, cada uma destravando o driver em cerca de 1 min.

8 Recomendações

1. **Driver: encerrar a sessão no** `turn.completed`**.** Ao ver o evento (ou o `.final`), esperar alguns segundos e matar o `codex exec` e os processos que ele criou, inclusive órfãos. Ler o `.txt`

com `FileShare.ReadWrite` e nova tentativa, e gravar a linha do estágio mesmo assim. É a causa dos 37 min ociosos e dos dois crashes.
2. **Kit: fechar o que abre.** `qa/pc.ps1`, `qa/phone.ps1` e o ciclo do emulador encerram o `pc.exe`, o servidor `adb` e o emulador que subiram, ao fim de cada execução. Candidato a `CLEAN-*`.
3. **Limites para tickets de QA real:** `-ImplementMinutes 90 -ReviewMinutes 40`. O SYN-025 levou 45 min na segunda tentativa e a primeira morreu no mesmo número.
4. **Mergear o PR #8** antes do próximo run: leva o `.gitignore` do kit para a `main` e acaba com a árvore suja depois de cada run.
5. **Stage 1 do Wi-Fi fora:** o critério 4 do SYN-024 deveria dizer o que conta como "Wi-Fi desligado" (estado `DISABLED` e a presença em 204), para a revisão não descer um nível por rodada.
6. **Celular destravado e aceso** nos runs do kit. Com PIN, o kit aborta antes de agir, e os critérios do aparelho viram débito.
7. **Manter `gpt-6.1-sol high` → `gpt-6.1-sol max` para filas de scripts e QA.** Apoia-se na linha `gpt-6.1-sol high | gpt-6.1-sol max` (29 revisões, 28 % de reabertura, S2 24 %) e no custo de $0,87–8,01 por ticket aqui. Não há outro implementador sob o mesmo revisor para comparar.

9 Débito humano

- SYN-022 critério 3: cenário físico com apenas USB.
- SYN-022 critério 4: resource-ids no dump real.
- SYN-022 critério 5 (parte): texto de bolha e `HEAD /listen` 200 com o Redmi no chat.
- SYN-022 critério 7: C.1/C.2 completos. O Redmi negava `settings put global` com `WRITE_SECURE_SETTINGS`.
- SYN-023 critério 4: Desparear pela engrenagem, `pair` com APK de debug, `Na rede` no dump e `HEAD /listen` 200 no Redmi.
- SYN-024 critério 3: D.1 completo (`share` abortou pelo bloqueio seguro).
- SYN-024 critério 4: Wi-Fi fora, transição de presença e reconexão no aparelho real.
- SYN-024 critério 5: chegada dos quatro arquivos ao Redmi (lado PC comprovado).
- SYN-024 critério 6: limpeza no MediaStore/`rm` do Redmi.
- SYN-024 critério 7: resource-ids no dump real.
- SYN-025, passo B.2 (não é linha `Débito humano:`, é humano por desenho): parear lendo o QR pela câmera do emulador, que o spike mostrou não ler.