Sweatshop no Codex: o kit de QA

gpt-6.1-sol (high) no stage 2, gpt-6.1-sol (max) no stage 3

Foreman, sessão `sweatshop/2026-09-30-2146`

30 de setembro a 1º de outubro de 2026

Resumo

Primeiro run da fila `.scratch/qa/` (o kit de QA, SYN-022 a SYN-026), com a escalação pedida para este run só (`-Models`), sem mexer no binding. É o primeiro run do kit contra o celular real (Redmi, adb sem fio).

- **Produzido:** 2 tickets mergeados na sessão (SYN-022, SYN-023), ambos *Approve* com `Review: agent`. SYN-024 foi reaberto uma vez, corrigido, e a segunda revisão morreu no limite de 20 min: fica em `to-review`. SYN-025 e SYN-026 não começaram. PR de sessão: #8.
- **Custo: $6,23** a preço de lista em 7 estágios com preço, mais 1 sem preço (a segunda revisão do SYN-024). Uma das 7, a revisão do SYN-022, saiu do `run-log` como "?" e foi recalculada pelo uso no `.txt` ($0,57). 142 min de estágio em 142 min de relógio (21:46–00:08); 17,9 M tokens de entrada (95,7 % em cache) e 127 k de saída.
- **O que deu errado: processos órfãos do kit**. O `codex exec` não termina enquanto um filho que a sessão abriu (`pc.exe`, o servidor `adb`) está vivo. O driver espera o processo: 30 min ociosos no SYN-022 e, no fim, um `throw` em `ReadAllText` com o `.txt` ainda preso por esses órfãos, que encerrou o run.
- **Veredito provisório:** barato ($1,41 e $1,46 por ticket mergeado) e rápido no trabalho real (8–23 min por estágio). A revisão em max é séria: reabriu o SYN-024 com quatro falhas reproduzidas. O par precisa de mais de 20 min de revisão quando a revisão faz QA no aparelho.

1 Linha do tempo

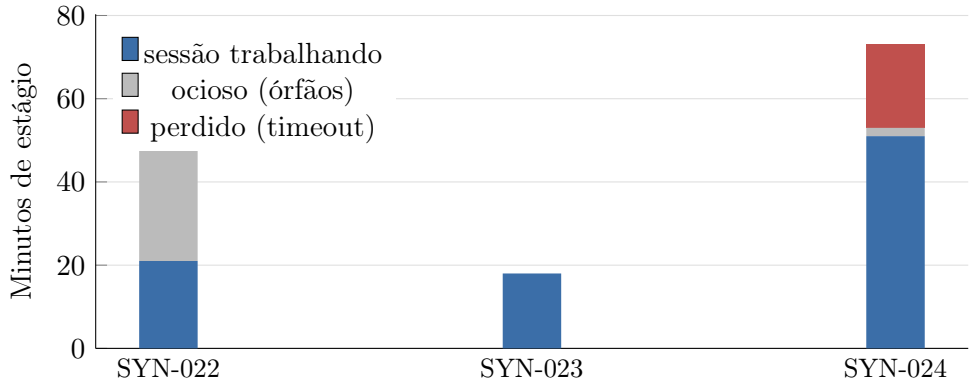
21:46	Lançamento. O foreman desfez uma mudança só de fim de linha no `Cargo.toml` para o Preflight ver a árvore limpa.
21:46	SYN-022, implementação. A sessão termina às 21:59 (`to-review`), mas o `codex exec` fica preso em `pc.exe` e `adb` órfãos. O foreman os derruba às 22:17 e o driver segue.
22:17	SYN-022, revisão: zero achados, mergeado. A sessão termina às 22:25; o driver espera até o limite de 20 min e mata o processo (custo "?").
22:37	SYN-023 (9 + 9 min), mergeado às 22:55; a revisão abre o CLEAN-018.
22:55	SYN-024, implementação (23 min). Por decisão do proxy, conserta a preparação opcional do kit (`6ad0599`): a negativa de `WRITE_SECURE_SETTINGS` vira aviso. O Redmi passa a barrar por PIN. O humano destrava o celular às 23:21.
23:19	SYN-024, revisão: **reabre** com quatro falhas e abre o CLEAN-019.
23:35	SYN-024, implementação 2 (13 min): as quatro corrigidas.
23:48	SYN-024, revisão 2. Às 23:49 o vigia automático do foreman derruba `pc.exe` e `adb` por engano (seção 7). A revisão faz QA de verdade no Redmi (recebimentos confirmados, Wi-Fi fora) e estoura os 20 min às 00:08.
00:08	O driver mata a revisão, tenta ler o `.txt`, preso pelos órfãos dela, e lança exceção. O `finally` atualiza o PR (2 tickets) e volta à `main`. O foreman derruba os órfãos (o arquivo solta), mas não consegue limpar a árvore da `main` para relançar (seção 7).

2 Métricas por estágio

Linhas de `.scratch/run-log.md` desde 21:46. Os tokens foram recontados a partir do evento `turn.completed` de cada `.txt`. "Min" é o que o log grava; entre parênteses, os minutos até a sessão terminar, quando o processo ficou preso depois. A segunda revisão do SYN-024 não tem linha no log: o driver caiu antes de gravá-la.

Estágio	Modelo	Min	Entrada	Cache	Saída	Custo	Desfecho
S22 impl.	high	31 (13)	2,34 M	96 %	20 k	0,84	to-review
S22 revisão	max	20 (8)	1,53 M	94 %	11 k	0,57*	mergeado
S23 impl.	high	9	2,43 M	97 %	12 k	0,76	to-review
S23 revisão	max	9	1,85 M	94 %	13 k	0,70	mergeado
S24 impl.	high	24 (23)	5,07 M	97 %	33 k	1,63	to-review
S24 revisão	max	16 (15)	2,41 M	94 %	23 k	0,96	reaberto
S24 impl. 2	high	13	2,28 M	96 %	15 k	0,77	to-review
S24 revisão 2	max	20	?	?	?	?	timeout, sem linha
Total		142	17,90 M	95,7 %	127 k	6,23	
Ocioso		32					esperando órfãos
Perdido		20	?		?	?	1 estágio sem preço

*O log grava "?" (processo morto no limite); recalculado pelo `.txt` com a tabela de preços do driver.



Onde foi o custo. Por ticket: SYN-024 $3,36 até aqui (mais a revisão 2 sem preço, ainda sem veredito), SYN-023 $1,46, SYN-022 $1,41. O custo em dólar quase não teve perda: o desperdício do run foi de tempo. Foram 32 min de driver parado esperando processos que já tinham feito o trabalho, mais os 20 min da revisão 2, que fazia QA real e não chegou a gravar o veredito.

3 Comparação

Números de `run-log.md`. O run de 27/09 é o do relatório `2026-09-27-sweatshop-claude.pdf`.

	Claude, 27/09	Codex gpt-6.1-sol, 30/09
Estágios	26	8 (7 no log)
Tickets mergeados	7	2
Minutos de estágio por ticket mergeado	49	21 / 18 (sem ociosidade)
Custo por ticket mergeado	$3,68–19,34	$1,41–1,46
Reaberturas	1	1
Minutos por implementação até `to-review`, média	13,0	14,5 (real)
Minutos por revisão concluída, média	11,4	10,7 (real)
Custo registrado	$59,99	$6,23

Ressalva forte: os tickets são de outro tipo. Os CLEAN de 27/09 mexiam no app com testes unitários; os SYN do kit escrevem scripts PowerShell e Node e tentam o celular real, e boa parte

dos critérios virou débito humano em vez de verificação. Com 2 tickets mergeados, a comparação é indicativa, não conclusiva.

4 Atribuição das reaberturas

Uma reabertura no run: SYN-024, rodada 1 (a primeira linha `reopened` do ticket no log), às 23:35. O revisor foi `gpt-6.1-sol max`, que não é o modelo do foreman (Opus 5.5), então o foreman classificou. Evidência: o ticket como estava no stage 2 (`fc384a2`), o diff `5f02f14..fc384a2` e a revisão (`9ca8337`). Linhas registradas em `.scratch/reopen-attribution.md`.

Ticket	Rodada	Rótulo	Achado e porquê
SYN-024	1	S2-explícito/código	`wifi-off` ignora o erro do `nohup` e sai 0 com `reconnected=true` quando `CHANGE_WIFI_STATE` é negado. O critério 9 e a lista de testes dizem que falha da ação pedida continua fatal.
SYN-024	1	S2-explícito/código ?	No PowerShell 5.1 com console 850, `prévia.txt` vira mojibake e `track` aceita o arquivo anterior. A lista de testes pede a recusa do arquivo anterior; o acento é o mesmo critério num nome comum em português.
SYN-024	1	S2-implícito	Upload interrompido deixa o arquivo com `hash=null`, e a limpeza o recusa para sempre. É caminho de falha do código que o próprio stage 2 escreveu.
SYN-024	1	S2-implícito	A normalização transforma `C:\` em `C:`, e os guards recusam a Pasta na raiz, que o app permite.

Totais: 2 S2-explícito (2 código, 0 teste), 2 S2-implícito, 0 S1, 0 S3. Sem *drip-feeding* nem *churn* (primeira rodada). A reabertura é do implementador. A revisão também abriu o CLEAN-019 (escape do extra de query do MediaStore) como achado sem critério, sem reabrir por ele, o que está certo.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre os quatro repositórios desta máquina com `.scratch/run-log.md` (SynchroNice, SIGAA-ME, EasyMath, PhysiSyst), depois de registrar a atribuição acima. Cumulativo.

Implementador	Estágios	To review	Falhou	Perguntou	Mediana até review	Custo
fable	1	1	0	0	11m	?
gpt-6-luna	8	4	4	0	37m	?
gpt-6-sol	6	5	1	0	17m	?
gpt-5.6-sol	5	4	1	0	17m	?
gpt-6-astra	18	11	6	1	8m	?
sonnet	5	3	2	0	14m	$10.53 (4/5)
sonnet-5 xhigh	11	6	2	3	8m	$18.09 (11/11)
gpt-6.1-sol high	28	24	0	4	7m	$16.16 (28/28)
opus-5.5	7	4	0	3	14m	$15.12 (7/7)
gpt-6-luna max	89	61	10	18	17m	$4.91 (85/89)
sonnet-5.5 high	2	2	0	0	7m	$3.77 (2/2)

Implementador	Revisor	Reviews	Reabertos	Taxa	Por S2	Taxa S2	Sem rótulo
fable	fable	1	1	100 %	0	≥0 %	1
?	opus	1	0	0 %	0	0 %	0
gpt-6-luna	gpt-6-sol	4	4	100 %	0	≥0 %	4
gpt-6-sol	gpt-5.6-sol	5	4	80 %	0	≥0 %	4
gpt-5.6-sol	gpt-6-astra	4	3	75 %	0	≥0 %	3
gpt-6-astra	gpt-5.6-sol	11	5	45 %	0	≥0 %	5
sonnet	opus	3	1	33 %	1	33 %	0
sonnet-5 xhigh	opus-5.5 xhigh	5	0	0 %	0	0 %	0
gpt-6.1-sol high	gpt-6.1-sol max	22	5	23 %	3	≥14 %	2
opus-5.5	opus-5.5	4	0	0 %	0	0 %	0
gpt-6-luna max	opus-5.5 high	18	1	6 %	1	6 %	0
gpt-6-luna max	gpt-6-sol max	43	23	53 %	22	51 %	0
?	gpt-6-sol max	1	0	0 %	0	0 %	0
sonnet-5.5 high	gpt-6-sol max	2	1	50 %	1	50 %	0

Implementador → Revisor	Rodadas	S2 expl. código	S2 expl. teste	S2 implícito	S1	S3 ruído
sonnet → opus	1	1	1	0	0	0
gpt-6.1-sol high → gpt-6.1-sol max	3	2	0	5	0	0
fable → ?	4	5	1	3	1	0
sonnet → ?	10	3	6	9	3	2
opus → ?	1	3	0	0	0	0
sonnet? → ?	11	3	4	12	3	5
gpt-6-luna max → opus-5.5 high	1	1	1	0	1	0
gpt-6-luna max → gpt-6-sol max	23	31	3	23	12	15
sonnet-5.5 high → gpt-6-sol max	1	3	0	2	0	0

O que mudou desde o relatório de 27/09.

- **Linhas novas:** `gpt-6.1-sol high` (28 estágios, 24 em `to-review`, nenhum falho, 7 min de mediana) e o par `gpt-6.1-sol high` → `gpt-6.1-sol max`: 22 revisões, 23 % de reabertura, taxa S2 ≥14 % com 2 reaberturas sem rótulo. Quase tudo vem do PhysiSyst; este run soma 3 revisões e 1 reabertura. Também são novas `sonnet-5.5 high` e os pares com `gpt-6-sol max` revisando.
- **Cresceu:** `gpt-6-luna max`, de 10 para 89 estágios, em outros repositórios.
- **Mesma implementação, revisores diferentes** (as duas com mais de 10 revisões): `gpt-6-luna max` reabre 6 % sob `opus-5.5 high` (18) e 53 % sob `gpt-6-sol max` (43), com S2 em 51 %. A diferença é do revisor, não do implementador.
- **Implementadores sob o mesmo revisor:** ninguém além do próprio `gpt-6.1-sol high` foi revisado por `gpt-6.1-sol max`; não dá para comparar implementadores por esta linha.

6 Observações sobre os modelos

gpt-6.1-sol (high), implementação

- **TDD limpo em todos:** commit de teste antes do código (`7d0028a`, `4d12967`, `95a46e1`, `5d65455`, `ced5962`; na volta, `87f73a8`, `e8494cf`, `c30cd73`, `4ac9157`), e prova vermelha registrada no ticket.
- **Pede ao proxy em vez de travar:** no SYN-022 e no SYN-024 a sessão chamou o agente `proxy` pelo Claude CLI (só leitura) e seguiu com a decisão registrada. Nenhum `blocked`.
- **Débito largo:** no SYN-023, atribuiu à negativa de `WRITE_SECURE_SETTINGS` um pareamento que talvez não dependa dela. O próprio SYN-024 tirou a causa depois.
- **Deixa processos abertos** (`pc.exe`, servidor `adb`) ao terminar. É a causa da ociosidade e do crash.

gpt-6.1-sol (max), revisão

- **Reproduz antes de reabrir:** as quatro falhas do SYN-024 vieram com repro (adb falso, console 850, Pasta temporária) e linha de código. Refez a prova vermelho-verde dos commits originais.
- **Separa achado de critério:** o que não tinha critério virou ticket (CLEAN-018, CLEAN-019), não motivo de reabertura.
- **Lenta com o aparelho:** a revisão 2 do SYN-024 fez QA real no Redmi (recebimentos, Wi-Fi fora com amostragem) e não coube nos 20 min.

7 Integração com o Codex e o driver

- `codex exec` **não sai com filhos vivos.** O driver faz `WaitForExit` no processo; um `pc.exe` ou servidor `adb` aberto pela sessão o segura até alguém matá-lo ou o limite estourar. Aconteceu em 4 de 8 estágios.
- `taskkill /T` **não alcança os órfãos:** o pai deles já morreu, então a árvore não os inclui, e eles continuam segurando o `stdout` redirecionado para o `.txt`.
- `ReadAllText` **sem tolerância a lock:** o arquivo preso derrubou o driver depois do timeout. Sem linha no log para o estágio.
- **Árvore suja na** `main` **depois do run:** `qa/node_modules` e os artefatos de `.scratch/qa-runs/` (174 arquivos) são ignorados na sessão, mas a `main` não tem esse `.gitignore`. O Preflight recusaria o relançamento. Mover os arquivos foi negado ao foreman pela permissão automática.
- **Run paralelo:** um sweatshop do PhysiSyst rodava ao mesmo tempo. Ele não usa `adb`; matar o servidor não o afetou.
- **Erro do foreman:** o vigia automático das 23:39 derrubava `pc.exe` e `adb` quando o driver ficava parado 60 s depois de um `.final`. Às 23:49 ele mediu tarde, com o driver já na revisão seguinte, e matou os dois no começo da revisão 2 do SYN-024. A revisão reabriu o `adb` às 23:52 e o app às 23:57; pode ter custado parte dos minutos que faltaram. O vigia foi corrigido às 23:50 para só agir quando a última linha do driver ainda é o lançamento daquele estágio.

8 Recomendações

1. **Driver: encerrar a sessão no** `turn.completed`**.** Ao ver o evento (ou o `.final`), esperar alguns segundos e matar o `codex exec` e os processos que ele criou, inclusive órfãos. Ler o `.txt` com `FileShare.ReadWrite` e nova tentativa. É a causa dos 32 min ociosos e do crash.
2. **Kit: fechar o que abre.** `qa/pc.ps1` e `qa/phone.ps1` encerram o `pc.exe` que iniciaram e o servidor `adb` que subiram (`adb kill-server`) ao fim de cada comando ou execução. Candidato a `CLEAN-*`.
3. **Relançar com** `-ReviewMinutes 40` enquanto a fila for do kit: revisão com QA no aparelho não cabe em 20 min.
4. **Limpar a árvore da** `main` **antes de relançar:** apagar ou mover `qa/` e `.scratch/qa-runs/` não rastreados (o `node_modules` é reinstalável; os artefatos de QA são locais de qualquer jeito), ou levar o `.gitignore` da sessão para a `main`.
5. **Celular destravado e aceso** nos runs do kit. Com PIN, o kit aborta antes de agir, e os critérios do aparelho viram débito.
6. **Manter** `gpt-6.1-sol high` → `gpt-6.1-sol max` **para esta fila.** Apoia-se na linha `gpt-6.1-sol high | gpt-6.1-sol max` (22 revisões, 23 % de reabertura, S2 ≥14 %) e no custo de $1,4 por ticket mergeado aqui. Não há outro implementador sob o mesmo revisor para comparar.

9 Débito humano

- SYN-022 critério 3: cenário físico com apenas USB.
- SYN-022 critério 4: resource-ids no dump real.
- SYN-022 critério 5 (parte): texto de bolha e `HEAD /listen` 200 com o Redmi no chat.
- SYN-022 critério 7: C.1/C.2 completos. O Redmi negava `settings put global` com `WRITE_SECURE_SETTINGS`.
- SYN-023 critério 4: Desparear pela engrenagem, `pair` com APK de debug, `Na rede` no dump e `HEAD /listen` 200 no Redmi.
- SYN-024 (na branch `syn-024`, ainda sem merge): critério 3 (D.1 completo), critério 4 (Wi-Fi fora: presença e reconexão), critério 5 (chegada dos quatro arquivos ao Redmi), critério 6 (limpeza no MediaStore/`rm`), critério 7 (resource-ids no dump real). O aparelho estava travado com PIN; a revisão 2, com o celular destravado, verificou parte disso, mas não gravou veredito.