Sweatshop: apagar tudo, em quatro escalações

astra low, sol high, sol high + hard sol max e sonnet-5.5 high + hard xhigh no stage 2; gpt-6.1-sol (max) no stage 3

Foreman, sessão `sweatshop/2026-10-01-2019`

1º a 3 de outubro de 2026

Resumo

Run longo sobre as filas `.scratch/core/` e `.scratch/android/`: colar imagem no Android (SYN-021), o BUG-003 (o PC perdia os enviados ao recarregar), a bandeja de envio do PC (SYN-020) e o "Apagar tudo" nos dois lados. O "Apagar tudo" (SYN-019 e SYN-027 originais) foi fatiado pelo proxy no meio do run em quatro tickets: SYN-019, SYN-027, SYN-028 e SYN-029. O stage 3 foi `gpt-6.1-sol max` do começo ao fim; o stage 2 trocou três vezes, por pedido do humano, sempre na linha de comando (`-Models`), nunca no binding.

- **Produzido: 7 tickets mergeados** na sessão, todos *Approve*; SYN-019 com `Review: human` (backend do Apagar tudo: rota nova do protocolo e originais da Pasta para a Lixeira). A fila ficou vazia ("Nothing runnable"). PR de sessão: #9.
- **Custo: $83,91** a preço de lista em 30 estágios com preço, mais 12 sem preço (7 erros de API, 4 timeouts e a revisão do SYN-020 que chegou aos 60 min). Por modelo: sol max $27,85 (+9 sem preço), sonnet-5.5 xhigh $23,10, astra low $19,03 (+2), sonnet-5.5 high $7,74, sol high $6,21 (+1). 1180 min de estágio em 28 h 35 de relógio; 185,0 M tokens de entrada (97,7 % em cache) e 1,07 M de saída.
- **O que deu errado: a cota do Codex**. Cinco limites de uso em 28 horas: o primeiro, com data na mensagem, derrubou o run 1; os outros quatro deixaram o driver dormindo 464 min no total. Somados a quatro timeouts e dois estágios que falharam por permissão, 289 dos 1180 min de estágio foram perdidos.
- **Veredito provisório:** `sonnet-5.5 high` é o implementador mais barato e rápido do run (14 min, $0,6–2,3 por implementação) e passou dois de quatro na primeira; `sonnet-5.5 xhigh` fechou os tickets duros (SYN-019, SYN-028, SYN-029), mas o SYN-029 custou $14,50 em duas implementações. `astra low` saiu caro ($8,8–10,2 por implementação) para um ticket só. A revisão em sol max continua dura e reproduz no emulador, mas fez *drip-feeding* duas vezes.

1 Linha do tempo

01/10, run 1: astra low → sol max

20:19 Lançamento, sem hard na escalação. SYN-021 implementação (30 min, $8,82).

21:08 SYN-021 revisão 1: **reabre** (colagem mista, Voltar em Configurações, tag de QA). Esta máquina não tinha emulador; um servidor `adb` órfão segurou o `codex exec` até o limite de 40 min.

21:56 SYN-021 implementação 2 (27 min, $10,21); revisão 2 mergeia às 22:17. O foreman instala emulador e imagem API 37 no SDK do D: e cria o AVD a pedido do humano.

22:47 BUG-003: limite de uso do Codex com data ("1:50 AM"); o driver lê como erro de API, relança, erra de novo e para. O humano usa um reset.

01–02/10, runs 2 e 3: sol high (+ hard sol max) → sol max

22:49 Relançado com sol high. 23:14: o humano pede hard em sol max.

23:31 BUG-003 implementação (41 min). O proxy fatia SYN-019/SYN-027 em quatro tickets (`608165d`) e o driver volta com hard sol max.

00:22 BUG-003 revisão: timeout aos 40 min (build do PC e QA). Relançado uma vez (causa de infraestrutura).

00:45 Limite de uso; o driver dorme até 03:51.

04:31 BUG-003 revisão: timeout de novo, já com os achados commitados (`1e8b32b`). **O proxy reabre** pelo veredito, sem terceira revisão. Relançado com `-ReviewMinutes 60`.

05:09 BUG-003 implementação 2 (28 min); revisão 2 mergeia às 05:55.

06:24 SYN-019 (hard, sol max): limite de uso, dorme até 08:52.

09:37 SYN-019: timeout aos 45 min com 7 commits; tentativa 2 continua da branch e chega a `to-review` às 09:54.

10:36 SYN-019 revisão 1: **reabre** (originais apagados, risco de concorrência). A implementação 2 estoura os 45 min às 11:21: é a segunda tentativa do ticket e ele vai a `blocked`.

11:53 SYN-020 implementação (sol high, 32 min). Revisão 1 **reabre** aos 60 min (imagem >10 MiB ganha miniatura).

13:02 Limite de uso. O humano troca o stage 2 para `sonnet-5.5 high`, hard `sonnet-5.5 xhigh`. O proxy manda retomar o SYN-019 da branch.

02–03/10, runs 6 e 7: sonnet-5.5 high + hard xhigh → sol max

14:03 As duas primeiras sessões Claude falham: o driver só liberava `Bash(powershell:*)` e o Sonnet usa a ferramenta PowerShell; um `pc.exe` órfão travava o `cargo`. O humano aprova a correção do driver (`7972d73`, Agent-Skills).

15:02 SYN-019 implementação (17 min). A revisão é recusada pelo Codex ("cybersecurity risk") ao reproduzir um deadlock; o driver relança.

15:54 SYN-019 revisão: **reabre** pela inversão de locks. Implementação (29 min) e revisão mergeiam às 16:42.

16:59 SYN-027 (17 + 17 min), mergeado de primeira às 17:16.

17:32 SYN-020 retomado (16 min). Limite de uso às 17:35, até 18:54; revisão 2 mergeia às 19:39 (45 min).

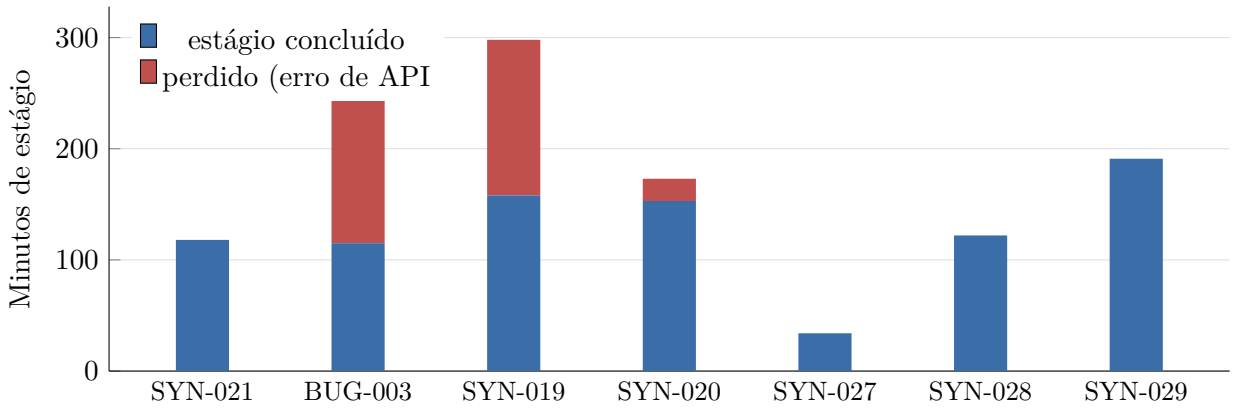
19:47 SYN-028 (8 min, sem testes por ordem do ticket). Revisão 1 **reabre** (três corridas da UI). O stage 2 chama o proxy, que aprova lápides num módulo puro (`442dc1a`). Revisão 2 **reabre** às 20:55; implementação 3 em xhigh; mergeado às 21:42.

22:35 SYN-029 implementação (52 min, $9,72). Revisão 1 **reabre** com sete achados às 23:22. Implementação 2 (42 min) e revisão 2 mergeiam às 00:54 de 03/10. "Nothing runnable"; PR #9 com 7 tickets.

2 Métricas por estágio

As 42 linhas de `.scratch/run-log.md` do run (dia/hora em que o estágio terminou). "?" é estágio que o driver não precificou: erro de API, timeout ou sessão morta no limite.

Fim	Estágio	Modelo	Min	Entrada	Cache	Saída	Custo	Desfecho
01/20:49	S21 impl.	astra low	30	6,7 M	98 %	14 k	8,819	to-review
01/21:29	S21 rev.	sol max	39	4,1 M	97 %	21 k	1,239	reaberto
01/21:56	S21 impl.	astra low	27	8,5 M	99 %	14 k	10,208	to-review
01/22:17	S21 rev.	sol max	22	2,3 M	96 %	13 k	0,761	mergeado
01/22:47	B3 impl.	astra low	29	?	?	?	?	erro de API
01/22:47	B3 impl.	astra low	0	?	?	?	?	erro de API
01/23:31	B3 impl.	sol high	41	9,3 M	98 %	28 k	2,525	to-review
02/00:22	B3 rev.	sol max	40	?	?	?	?	timeout
02/00:45	B3 rev.	sol max	20	?	?	?	?	erro de API
02/04:31	B3 rev.	sol max	40	?	?	?	?	timeout
02/05:09	B3 impl.	sol high	28	6,4 M	98 %	22 k	1,735	to-review
02/05:55	B3 rev.	sol max	46	9,9 M	98 %	45 k	2,731	mergeado
02/06:24	S19 impl.	sol max	30	?	?	?	?	erro de API
02/09:37	S19 impl.	sol max	45	?	?	?	?	timeout, nova tentativa
02/09:54	S19 impl.	sol max	17	4,0 M	94 %	19 k	1,443	to-review
02/10:36	S19 rev.	sol max	42	7,3 M	98 %	44 k	2,163	reaberto
02/11:21	S19 impl.	sol max	45	?	?	?	?	timeout, blocked
02/11:53	S20 impl.	sol high	32	6,9 M	98 %	31 k	1,945	to-review
02/12:53	S20 rev.	sol max	60	?	?	?	?	reaberto
02/13:02	S20 impl.	sol high	8	?	?	?	?	erro de API
02/14:03	S19 impl.	sonnet xhigh	2	1,4 M	96 %	7 k	0,905	falhou, blocked
02/14:13	S20 impl.	sonnet high	10	2,1 M	97 %	8 k	1,011	falhou, nova tentativa
02/15:02	S19 impl.	sonnet xhigh	17	2,8 M	97 %	19 k	1,568	to-review
02/15:20	S19 rev.	sol max	18	?	?	?	?	erro de API
02/15:54	S19 rev.	sol max	34	7,6 M	98 %	39 k	2,200	reaberto
02/16:23	S19 impl.	sonnet xhigh	29	5,9 M	97 %	62 k	3,863	to-review
02/16:42	S19 rev.	sol max	19	5,2 M	97 %	23 k	1,533	mergeado
02/16:59	S27 impl.	sonnet high	17	3,4 M	97 %	34 k	2,263	to-review
02/17:16	S27 rev.	sol max	17	3,5 M	97 %	20 k	1,068	mergeado
02/17:32	S20 impl.	sonnet high	16	1,2 M	97 %	5 k	0,615	to-review
02/17:35	S20 rev.	sol max	2	?	?	?	?	erro de API
02/19:39	S20 rev.	sol max	45	12,7 M	99 %	55 k	3,440	mergeado
02/19:47	S28 impl.	sonnet high	8	2,7 M	95 %	16 k	1,860	to-review
02/20:20	S28 rev.	sol max	32	6,4 M	98 %	43 k	1,962	reaberto
02/20:35	S28 impl.	sonnet high	15	3,2 M	96 %	25 k	1,989	to-review
02/20:55	S28 rev.	sol max	20	4,9 M	98 %	23 k	1,425	reaberto
02/21:20	S28 impl.	sonnet xhigh	25	3,5 M	97 %	38 k	2,260	to-review
02/21:42	S28 rev.	sol max	22	5,4 M	98 %	26 k	1,574	mergeado
02/22:35	S29 impl.	sonnet xhigh	52	9,8 M	95 %	189 k	9,723	to-review
02/23:22	S29 rev.	sol max	48	9,3 M	98 %	54 k	2,712	reaberto
03/00:04	S29 impl.	sonnet xhigh	42	14,6 M	98 %	89 k	4,776	to-review
03/00:54	S29 rev.	sol max	49	14,0 M	99 %	46 k	3,595	mergeado
Total			1180	185,0 M	97,7 %	1072 k	83,91	30 com preço
Perdido			289	?		?	?	12 sem preço



Onde foi o custo. Por ticket, só estágios com preço: SYN-021 $21,03, SYN-029 $20,81, SYN-019 $13,68 (+6 sem preço), SYN-028 $11,07, SYN-020 $7,01 (+3), BUG-003 $6,99 (+5), SYN-027 $3,33. O SYN-021 é caro pelo implementador (astra low gastou $19,03 em duas implementações); o SYN-029 pela primeira implementação em xhigh (189 k tokens de saída, a maior do run). A perda foi de tempo: 289 min em estágios sem desfecho (107 de erro de API, 170 de timeout, 12 de falha) e mais 464 min de relógio esperando a cota do Codex voltar, fora dos estágios.

3 Comparação

Números de `run-log.md`. O run de 30/09–01/10 é o do relatório `2026-09-30-sweatshop-gpt-6.1-sol.pdf`.

	sol high, 30/09–01/10	misto, 01–03/10
Estágios no log	16	42
Tickets mergeados	5	7
Minutos de estágio por ticket mergeado	70	169
Minutos por ticket, mediana	51 (13–148)	173 (34–298)
Custo por ticket mergeado (com preço)	$0,87–8,01	$3,33–21,03
Reaberturas	3	8 (7 no log + BUG-003)
Minutos por implementação até `to-review`, média	16,4	26,4
Minutos por revisão concluída, média	14,5	35,4
Custo registrado	$15,97	$83,91

Ressalva forte: os tickets são de outro tipo. O kit de QA eram scripts; aqui há concorrência no backend Rust (locks, Lixeira), corridas na UI do PC e o app Android, quase sempre com QA no emulador na revisão. A revisão média subiu de 14,5 para 35,4 min por isso.

Por implementador, neste run (revisões concluídas, contando a reabertura do BUG-003 decidida pelo proxy; anedota, todas abaixo de 10):

Implementador	Implementações até review	Min, média	Revisões	Reabertas
gpt-6-astra low	2	28,5	2	1
gpt-6.1-sol high	3	33,7	3	2
gpt-6.1-sol max (hard)	1	17,0	1	1
sonnet-5.5 high	4	14,0	4	2
sonnet-5.5 xhigh (hard)	5	33,0	5	2

4 Atribuição das reaberturas

Sete rodadas reabertas, 22 achados. Seis rodadas têm linha `reopened` no log; a rodada 1 do BUG-003 não tem: a revisão estourou o tempo depois de commitar os achados (`1e8b32b`) e o proxy reabriu pelo veredito, então o driver gravou timeout. O revisor de todas foi `gpt-6.1-sol max`, que não é o modelo do foreman (Opus 5.5); a classificação foi feita por um subagente Opus 5.5 com a rubrica e as evidências (o ticket no stage 2, o diff da rodada e a revisão), e o foreman só corrigiu a data das linhas do SYN-029 para 02/10, a do log. Linhas em `.scratch/reopen-attribution.md`.

Ticket	R	Impl.	Rótulo	Achado	Porquê
BUG-003	1	gpt-6.1-sol high	S2-explícito/código ?	Abrir uma segunda instância com a mesma pasta de dados apaga a cópia de print de uma Sessão viva: `Outbox::new` e o `Drop` de `Inner` removem a pasta `session-files` inteira	O critério 3 e a decisão "a cópia vive até a Sessão acabar" estão no ticket, e a falta de instância única já está anotada no SYN-005 e em `.scratch/qa/spec.md`; o ? porque a própria decisão do stage 1 dizia "a pasta é varrida quando a fila é criada", e separar instância viva de morta pede um mecanismo (pasta por instância com lock), quase S1. O revisor de 23:42, que estourou o tempo, já suspeitava deste ponto (1e8b32b)
BUG-003	1	gpt-6.1-sol high	S2-implícito	O `Promise.all` de `list_items` e `list_sent_items` rejeita quando a fila não foi criada, e `main()` aborta antes de desenhar os recebidos e de ligar composer, drop, colar e engrenagem	Regressão da própria mudança num caminho de falha; o modo de falha já tinha precedente na correção 2 da revisão de SYN-005. Sem teste a cobrar: `main.ts` não tem seam (1e8b32b)
SYN-019	1	gpt-6.1-sol max	S2-implícito	`Items::file_done` é chamado com `received_files` travado, e um observador de `Done` que consulta `Running::caminho_do_arquivo` trava a conclusão do upload	Regressão da costura pública que o próprio stage 2 escreveu: antes do diff o lock era solto antes do callback. Nada no ticket fala de callbacks (8ac2715)
SYN-019	1	gpt-6.1-sol max	S2-explícito/código	Um `enqueue_file_from_path` entre a captura de `session_items` e o descarte registra um envio cujo original vai para a Lixeira	A decisão "o original de quem enviou nunca é tocado" está no ticket, e o stage 2 listou originais de enviados no próprio plano; a corrida é do código que ele escreveu. Achado estático, que o teste vermelho de `4c01564` confirmou depois (8ac2715)
SYN-019	1	gpt-6.1-sol max	S2-explícito/código	Excluir um recebido antigo entre o rename e o registro do caminho de um upload novo, com o mesmo caminho e o mesmo tamanho, recicla o arquivo do upload novo	O critério 7 e a decisão "nenhum Item mais novo da Sessão usa o mesmo caminho" estão no ticket, e o gancho `after_file_rename` já mostrava essa janela. O teste vermelho de `272a338` confirmou depois (8ac2715)
SYN-019	1	gpt-6.1-sol max	S2-explícito/código	Receber R, reenviar o arquivo de R como S, excluir só S e depois só R apaga o original, porque a proteção só conta os enviados que ainda estão na lista	A decisão "o original de quem enviou nunca é tocado" e o `CONTEXT.md` dizem isso, e a sequência é simples, sem corrida. Reproduzido no kit (8ac2715)
SYN-019	1	gpt-6.1-sol max	S2-explícito/código ?	Reenviar uma cópia interna por um caminho com outra capitalização e excluir só a cópia apaga o original do outro enviado: `outbox.rs` compara `PathBuf` literalmente	Os critérios 7 e 8 e a mesma regra do original estão no ticket. Lembrar que caminhos do Windows não diferenciam maiúsculas é cuidado, não decisão, mas é conhecimento de fora do ticket, daí o ?. Reproduzido no kit (8ac2715)
SYN-019	2	sonnet-5.5 xhigh	S2-implícito	A exclusão trava `received_files` e depois espera `Items`, enquanto `file_done` segura `Items` durante o `on_new`, e o observador que consulta o caminho espera o mapa: inversão de locks que trava exclusão e upload	O caminho de concorrência do callback que o stage 2 tinha acabado de corrigir; `f7012fb` tirou só o autodeadlock. Drip-feeding: a ordem mapa → Items já estava em `e031567`, e o revisor admite que a primeira passagem deixou essa variante passar. Churn parcial: `finish_received_file`, que também consulta `Items` com o mapa travado, nasceu da correção do rename pedida pela rodada 1 (2b8b512)

Ticket	R	Impl.	Rótulo	Achado	Porquê
SYN-020	1	gpt-6.1-sol high	S2-explícito/código	Uma imagem colada acima de 10 MiB ainda ganha miniatura: `adicionarImagem` cria a URL para todo `File` sem olhar o tamanho	O critério 11 diz "o de imagem, colada ou por caminho" e "acima de 10 MiB aparece como chip de documento"; o stage 2 só limitou o caminho que passa por `previa_de_caminho`. Reproduzido com `paste-image` nativo (e94db12)
SYN-020	1	gpt-6.1-sol high	S2-implícito	Oito commits do stage 2 não têm o corpo explicativo que o fluxo exige	Convenção que o `ticket-flow` já impõe. É uma divergência de processo e não foi o motivo da reabertura (e94db12)
SYN-028	1	sonnet-5.5 high	S2-explícito/código	Quando o timer de 5 s expira, `janelaDeDesfazer` é zerada antes de o `apagar_tudo` voltar, e progresso ou ACK de upload recriam a bolha selecionada, que fica na tela com o backend vazio	O critério 1 diz "o clique esvazia o chat"; a corrida é do código assíncrono que o próprio stage 2 escreveu. Reproduzido com IPC retido. Sem `/teste`: o ticket mandava o stage 2 não escrever testes (293a2bd)
SYN-028	1	sonnet-5.5 high	S2-explícito/código	Um snapshot atrasado do Desfazer, e da carga inicial, devolve a bolha de um Item que o celular já excluiu	O critério 4 está no ticket, e o stage 2 anotou que o Desfazer refaz o snapshot. Reproduzido duas vezes no Desfazer; a variante da carga inicial foi conferida só no código. O ticket mandava não escrever testes (293a2bd)
SYN-028	1	sonnet-5.5 high	S2-explícito/código	Recarregar depois do Apagar tudo mostra de novo um upload selecionado que ainda está recebendo, porque `list_items` não filtra a exclusão diferida	O critério 3 está no ticket, e a exclusão diferida do upload é uma decisão do SYN-019, que o ticket manda ler. Reproduzido no caminho estável. Corrigir pedia só cuidado; o `proxy` decidiu as costuras de teste, não a correção (293a2bd)
SYN-028	2	sonnet-5.5 high	S2-explícito/código	`recebidos_visiveis` lê `Items::snapshot()` e `delete_requested()` com locks separados, e um upload que termina entre as duas leituras volta na recarga	O critério 3 está no ticket; o defeito é do helper novo da rodada 2, não uma omissão da primeira passagem. Não é churn: o conselho da rodada 1 só pedia o filtro, e a corrida está na implementação. O teste vermelho de `2905b50` confirmou depois (4502b82)
SYN-028	2	sonnet-5.5 high	S2-explícito/código	`main()` registra `item` e `enviado` antes de `apagado`, com um `await` entre eles, e um Item que chega e é excluído nesse intervalo fica como bolha residual	O critério 4 está no ticket; é a corrida de inicialização do código que o stage 2 escreveu. Drip-feeding: o código já estava em `09228ef`, e o revisor admite que foi omissão da primeira passagem. Reproduzido duas vezes (4502b82)
SYN-029	1	sonnet-5.5 xhigh	S2-explícito/código ?	Com o ACK incompleto, `files.delete(uri, null)` pula a checagem de tamanho e pode apagar um arquivo completo que foi alterado depois	A decisão "Segurança antes de apagar" (só a URI gravada e só com o tamanho do Item; na dúvida, não apaga) está no ticket. O ? porque a mesma prosa manda apagar o download que falha, e o eixo Spec classificou o achado como limpeza sem veto (41da116)
SYN-029	1	sonnet-5.5 xhigh	S2-implícito	Se a fila não consegue persistir a exclusão (`IOException`), `commitClear` derruba o app depois de já ter tirado bolhas, `submitted` e recebidos	Caminho de falha do código que o stage 2 escreveu; os caminhos de texto, composer e câmera já tratam erro de persistência, e o código novo não segue essa convenção (41da116)

Ticket	R	Impl.	Rótulo	Achado	Porquê
SYN-029	1	sonnet-5.5 xhigh	S2-explícito/código	O prazo de 5 s mora no `ClearedNotice`, é cancelado quando as Configurações abrem e recomeça ao voltar, então a exclusão pode ser adiada sem fim	O critério 3 diz "Desfazer em até 5 s" e "sem desfazer, os arquivos saem". O próprio stage 2 registrou isso como "limite aceito" (3), o que não o tira do contrato. Reproduzido no emulador (41da116)
SYN-029	1	sonnet-5.5 xhigh	S2-explícito/código	Depois de um download interrompido, a URI parcial fica só no recibo `writing:`; `dropMessages` não apaga o arquivo e ainda impede a retomada	Os critérios 3 e 4 e a decisão "um arquivo ainda baixando é apagado quando o download termina ou falha" estão no ticket (41da116)
SYN-029	1	sonnet-5.5 xhigh	S2-explícito/código	Uma exclusão que chega entre o registro em `inFlightFiles` e a criação da bolha sai com ACK, e depois o recebimento cria uma bolha FAILED	O critério 4 e a decisão sobre download em andamento estão no ticket; a corrida é do código que o stage 2 escreveu. O limite (4) do stage 2 tratava de outro caso (41da116)
SYN-029	1	sonnet-5.5 xhigh	S2-explícito/código	A bolha de texto criada em `addOutgoing` ainda não tem UUID: se o Apagar tudo vence o enfileiramento, o id fica fora da exclusão e `queueText` envia o texto apagado	O critério 2 pede "ids de protocolo de todas as mensagens apagadas". O stage 2 registrou isso como "limite aceito" (2) (41da116)
SYN-029	1	sonnet-5.5 xhigh	S2-explícito/código ?	O centro do novo lixeira fica sob a barra de status e não responde ao toque no emulador	O critério 3 diz "o toque esvazia o chat", e a correção é só cuidado (`statusBarsPadding`). O ? porque o cabeçalho sem inset já existia antes do ticket: a e o Voltar das Configurações têm o mesmo problema, e o lixeira só o herdou. Achado do QA (41da116)

Totais: 17 S2-explícito/código (4 com ?), 0 S2-explícito/teste, 5 S2-implícito, 0 S1, 0 S3. Todas as reaberturas são do implementador. O SYN-028 não tem `/teste` porque o ticket mandava o stage 2 não escrever testes na rodada 1.

O que é do stage 3. *Drip-feeding* em duas rodadas, as duas admitidas pela própria revisão: SYN-019 rodada 2 (a ordem de locks mapa → Items já estava em `e031567`) e SYN-028 rodada 2 (o ouvinte `apagado` registrado tarde já estava em `09228ef`). *Churn* parcial no SYN-019 rodada 2: `finish_received_file`, que consulta `Items` com o mapa travado, nasceu da correção do rename que a rodada 1 pediu.

Limites "aceitos" pelo stage 2. Dois dos sete achados do SYN-029 (o prazo de 5 s pausado nas Configurações e o texto sem UUID que escapa do Apagar tudo) estavam escritos no ticket pelo próprio stage 2 como limites aceitos. A rubrica os conta como S2-explícito/código: declarar não tira do contrato. É a recomendação 5.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre os quatro repositórios desta máquina com `.scratch/run-log.md` (SynchroNice, SIGAA-ME, PhysiSyst, slip), depois de registrar a atribuição acima. Cumulativo.

Implementer	Stage runs	To review	Failed	Asked	Median min to review	Cost
fable	5	5	0	0	3m	?
sonnet	121	75	31	15	7m	$10.53 (4/121 priced)
gpt-6-luna	23	11	10	2	26m	?
gpt-6-sol	6	5	1	0	17m	?
gpt-5.6-sol	5	4	1	0	17m	?
gpt-6-astra	18	11	6	1	8m	?
sonnet-5 xhigh	11	6	2	3	8m	$18.09 (11/11 priced)
gpt-6.1-sol high	38	33	0	5	8m	$29.32 (38/38 priced)
gpt-6-astra low	2	2	0	0	30m	$19.03 (2/2 priced)
gpt-6.1-sol max	3	1	2	0	17m	$1.44 (1/3 priced)
sonnet-5.5 xhigh	9	8	1	0	25m	$35.54 (9/9 priced)
sonnet-5.5 high	16	15	1	0	7m	$28.15 (16/16 priced)
opus-5.5	35	31	4	0	6m	$0.72 (1/35 priced)
opus-5.5 high	2	2	0	0	9m	$2.31 (2/2 priced)
gpt-6-astra medium	4	2	0	2	11m	$8.01 (4/4 priced)

Implementador	Revisor	Reviews	Reabertos	Taxa	Por S2	Taxa S2	Sem rótulo	S2 na revisão
fable	fable	4	1	25%	0	≥0%	1	0
?	opus	4	0	0%	0	0%	0	0
sonnet	opus	68	20	29%	1	≥1%	19	0
gpt-6-luna	gpt-6-sol	11	7	64%	0	≥0%	7	0
gpt-6-sol	gpt-5.6-sol	5	4	80%	0	≥0%	4	0
gpt-5.6-sol	gpt-6-astra	4	3	75%	0	≥0%	3	0
gpt-6-astra	gpt-5.6-sol	11	5	45%	0	≥0%	5	0
sonnet-5 xhigh	opus-5.5 xhigh	5	0	0%	0	0%	0	0
gpt-6.1-sol high	gpt-6.1-sol max	32	8	25%	7	22%	0	0
gpt-6-astra low	gpt-6.1-sol max	2	1	50%	1	50%	0	0
gpt-6.1-sol max	gpt-6.1-sol max	1	1	100%	1	100%	0	0
sonnet-5.5 xhigh	gpt-6.1-sol max	7	3	43%	3	43%	0	0
sonnet-5.5 high	gpt-6.1-sol max	12	3	25%	3	25%	0	0
sonnet	fable	1	0	0%	0	0%	0	0
opus-5.5	fable-5.1	30	1	3%	0	≥0%	1	0
opus-5.5 high	fable-5.1 high	1	0	0%	0	0%	0	0
opus-5.5 high	opus-5.5 xhigh	1	0	0%	0	0%	0	0
sonnet-5.5 high	opus-5.5 xhigh	3	0	0%	0	0%	0	3
sonnet-5.5 xhigh	opus-5.5 xhigh	1	0	0%	0	0%	0	0
gpt-6-astra medium	gpt-6-astra xhigh	2	0	0%	0	0%	0	0

Implementer → Reviewer	Rounds	S2 explicit code	S2 explicit test	S2 implicit	S1	S3 noise
sonnet → opus	1	1	1	0	0	0
gpt-6.1-sol high → gpt-6.1-sol max	9	5	0	9	1	0
gpt-6-astra low → gpt-6.1-sol max	1	2	0	1	0	0
gpt-6.1-sol max → gpt-6.1-sol max	1	4	0	1	0	0
sonnet-5.5 xhigh → gpt-6.1-sol max	3	7	0	3	2	0
sonnet-5.5 high → gpt-6.1-sol max	3	5	0	2	3	0
sonnet-5.5 high → opus-5.5 xhigh	3	1	2	0	0	0

O que mudou desde o relatório de 30/09.

- **Linhas novas sob `gpt-6.1-sol max`:** `sonnet-5.5 xhigh` (7 revisões, 43 % de reabertura, S2 43 %), `gpt-6-astra low` (2) e `gpt-6.1-sol max` implementando (1). As três estão abaixo de 10 revisões: anedota.
- **`sonnet-5.5 high` → `gpt-6.1-sol max`** passou de 2 para 12 revisões e de 50 % para 25 % de reabertura (S2 25 %). Ainda perto de anedota.
- **`gpt-6.1-sol high` → `gpt-6.1-sol max`:** de 29 para 32 revisões, reabertura de 28 % para 25 %, S2 de 24 % para 22 %. Sem reabertura sem rótulo: não é piso. A rodada 1 do BUG-003 entra nos achados (9 rodadas) mas não nas revisões, porque o log a gravou como timeout.
- **Implementadores sob o mesmo revisor** (`gpt-6.1-sol max`): `gpt-6.1-sol high` 22 % S2 em 32 revisões e `sonnet-5.5 high` 25 % em 12. Iguais com essas amostras. Por estágio, sol high custa $0,77 e sonnet-5.5 high $1,76 a preço de lista; as medianas até review são 8 e 7 min.
- **xhigh não reabriu menos que high** sob o mesmo revisor (43 % em 7 contra 25 % em 12), embora tenha recebido os tickets duros. Anedota; o par só diz que o esforço maior não comprou a primeira aprovação nos tickets de concorrência.

6 Observações sobre os modelos

gpt-6-astra (low), implementação

- **Caro para o que entregou:** 6,7 e 8,5 M tokens de entrada, $8,82 e $10,21 por implementação de um ticket de colar imagem. É o maior custo por implementação do run depois do SYN-029 em xhigh.
- Reabertura com dois achados que estavam no contrato do ticket.

gpt-6.1-sol (high e max), implementação

- **TDD limpo** no BUG-003 e no SYN-020, como no run anterior.
- **Em max, como hard, não coube nos 45 min:** o SYN-019 estourou duas vezes com trabalho real nas branches; a segunda contou como a segunda tentativa do ticket e o bloqueou.
- **Deixa processos vivos:** um `pc.exe` de uma sessão morta pelo limite de uso travou o `cargo` da sessão seguinte.

sonnet-5.5 (high e xhigh), implementação

- **high é rápido e barato:** 8–17 min, $0,62–2,26. SYN-027 passou de primeira (com prova vermelha só de compilação, que a revisão aceitou).
- **xhigh prova com revert:** no SYN-028 e no SYN-019 conferiu que cada teste novo falha desfazendo o conserto, e reescreveu um teste que passava no código velho.
- **Aceita limites sozinho:** no SYN-029 escreveu "limites aceitos" que feriam os critérios 2 e 3; a revisão reprovou os dois. Na rodada 2 voltou a declarar dois limites, que a revisão aceitou.
- **Leu errado o próprio `.err`:** o aviso `unrecognized_model claude-sonnet-5-5`, presente em toda sessão sonnet-5.5, foi relatado como "o run morreu no lançamento" no `.final` do próprio run que funcionou.
- **Chama o proxy:** no SYN-028 o stage 2 pediu a decisão do plano da reabertura ao proxy antes de codar (`442dc1a`).

gpt-6.1-sol (max), revisão

- **Reproduz no emulador e no app:** os de UI do SYN-028 e do SYN-029 vieram reproduzidos pelo kit; a Lixeira foi conferida por SHA-256.
- **Drip-feeding** no SYN-019 (rodada 2) e no SYN-028 (rodada 2), admitido pela própria revisão nos dois.
- **Lenta:** 35 min por revisão concluída; duas morreram aos 40 min (BUG-003) e uma chegou aos 60 (SYN-020) insistindo numa captura do Computer Use que expirava.
- **Recusa do Codex:** ao reproduzir um deadlock no SYN-019, a sessão foi cortada por "possible cybersecurity risk".

7 Integração com o Codex, o Claude e o driver

- **Cota do Codex:** cinco limites de uso (01/10 22:47; 02/10 00:45, 06:24, 13:02, 17:35). O driver espera reset com hora (464 min no total), mas leu o reset com data como erro de API e parou.
- **Tentativas por ticket, não por rodada:** o SYN-019 foi a `blocked` com um timeout na rodada 1 e outro na rodada 2.
- **Erro de API num ticket reaberto** deixa a branch com o `Stage: implementing` commitado; o Preflight recusou o relançamento ("Tickets mid-run: SYN-020") até o foreman limpar.
- **Permissões do Claude:** o `-allowedTools` só tinha `Bash(powershell:*)`; o Sonnet chama o gate pela ferramenta PowerShell. Dois estágios falharam até `7972d73`.
- **Recusa por cibersegurança** não é reconhecida como recusa: o driver a tratou como rede e relançou (funcionou; uma segunda teria parado o run como "API unreachable twice").

- **`adb` órfão** herdou o pipe do `codex exec` e segurou a revisão 1 do SYN-021 até o limite.
- **Kit de QA nesta máquina:** sem emulador no começo; instalado no SDK do D:, com junção do caminho padrão do `up.ps1`. O `down.ps1` ainda pede `-Sdk`. Com o emulador de pé, o D: (HDD) fica em 100 % de uso.
- **Gate:** o Gradle do gate completo reaproveita (`UP-TO-DATE`) os testes da rodada `-TestsOnly`.

8 Recomendações

1. **Driver: zerar as tentativas quando a revisão reabre.** Um timeout por rodada não é o mesmo ticket falhando duas vezes (SYN-019).
2. **Driver: erro de API desfaz o `implementing`** da branch mantida, para o Preflight não recusar o relançamento (chip aberto no run).
3. **Driver: reconhecer o reset com data** do limite de uso e a recusa por cibersegurança, cada um com seu caminho, em vez de cair em `NetFail`.
4. **Limites: manter `-ImplementMinutes 75 -ReviewMinutes 60`** nos tickets com QA no emulador; nenhum estágio estourou depois da troca.
5. **ticket-flow: o stage 2 não aceita limite que toca critério.** Vai ao proxy. Dois dos sete achados da rodada 1 do SYN-029 eram limites que o stage 2 declarou aceitos.
6. **Stage 1: ticket de cola de UI sem testes de stage 2** (SYN-028) reabriu duas vezes por corridas; o conserto acabou criando um módulo puro testável. Pedir esse módulo já no ticket.
7. **Escalação:** `sonnet-5.5 high` e `gpt-6.1-sol high` empatam sob `gpt-6.1-sol max` (linhas `gpt-6.1-sol high` → `gpt-6.1-sol max`, 32 revisões, S2 22 %, e `sonnet-5.5 high` → `gpt-6.1-sol max`, 12 revisões, S2 25 %). Escolher pela cota: com o Codex batendo no limite cinco vezes, o stage 2 em Claude tira carga dele. Não pagar xhigh no hard por enquanto: `sonnet-5.5 xhigh` → `gpt-6.1-sol max` (7 revisões, anedota) não reabriu menos que high, e o SYN-029 custou $14,50 de implementação.
8. **Triagem dos flaky fora de ticket:** `pc/src-tauri/tests/server.rs:819` (10053 ConnectionAborted), `ProtocolClientTest` "arquivo grande aceito sem resposta" e `ListenLoopTest.listenReopensWhileALargeDownloadIsStillInProgress`.
9. **Mergear o PR #9** antes do próximo run.

9 Débito humano

Do run (`grep -rh 'Débito humano:' .scratch/` na sessão, só as linhas deste run). Sem aparelho: o humano estava sem o celular, todo QA foi no emulador e o passo do Redmi pós-run não rodou.

- SYN-021 critério 7: colar imagem pelo teclado/menu e ver a bandeja, remover pelo , Voltar com a bandeja cheia, câmera enviando direto.
- BUG-003: arrastar uma bolha enviada para fora da janela (a captura do Computer Use falhou duas vezes).
- SYN-020: drop nativo e arrastar uma bolha de volta à janela.
- SYN-020 critério 8: esconder e reabrir a janela com a bandeja preservada.