Sweatshop: gpt-6.1-sol no modo fast

gpt-6.1-sol-fast (high) no stage 2, (max) no stage 3 e no hard

Foreman, sessão `sweatshop/2026-10-04-1210`

4 de outubro de 2026

Resumo

Run curto sobre a fila `.scratch/qa/`: CLEAN-027, CLEAN-030 e CLEAN-032, triados pelo proxy logo antes do lançamento. Pedido do humano: testar o *fast* do Codex, com `gpt-6.1-sol high` no stage 2 e `gpt-6.1-sol max` no stage 3 e no hard, todos no tier fast. O driver ganhou o token `fast` para isso (`b18746c`, Agent-Skills): a linha vira `gpt-6.1-sol-fast` no log e o `codex exec` recebe `-config service_tier=fast`.

- **Produzido: 3 tickets mergeados**, todos de primeira, todos *Approve*. PR de sessão: #11. A revisão do CLEAN-032 abriu o CLEAN-033 (`needs-triage`) em vez de reabrir.
- **Custo: $7,57 registrado** (1 de 7 estágios com preço): o preço do fast (o dobro da linha base) só entrou no driver no meio do run (`dc530fb`). Aplicando esse preço ao uso que os próprios logs registram, os seis estágios concluídos somam **$24,97**, mais a revisão que estourou o limite, sem uso registrado. 211 min de estágio em 3 h 36 de relógio (12:10–15:46); 43,9 M tokens de entrada (97,8 % em cache) e 197 k de saída.
- **O que deu errado:** a primeira revisão do CLEAN-032 **estourou os 40 min** no meio do gate, com a CPU dividida entre este run e mais dois runs sol-fast em outros repositórios (PhysiSyst desde 12:43, ClassyCall desde 13:26). Relançada com 60 min, terminou aos 59:54.
- **Veredito provisório:** o fast **acelerou a implementação** (mediana 15 min contra 24 do sol normal neste repositório), a cerca de 1,8 vez o custo; **não acelerou a revisão** (33 contra 28 min), que aqui é presa ao gate e ao emulador, a 3,3 vezes o custo. Três tickets e concorrência na máquina: anedota, não medida.

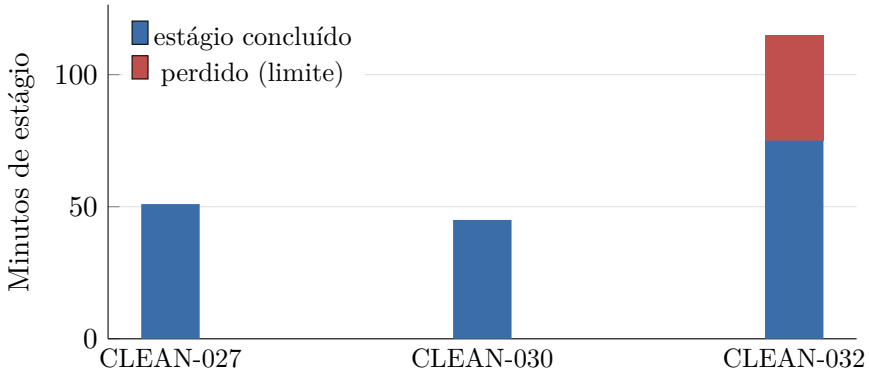
1 Linha do tempo

12:09	Triagem e stage 1 dos três tickets pelo proxy (`70534d5`).
12:10	Lançamento destacado (pid 14576). CLEAN-027 implementação (18 min): here-document no stdin do `grep`, vermelho no harness que emula o mksh do aparelho.
12:28	CLEAN-027 revisão (33 min): `wifi-off` real no `SynchroNice_API37` com dump de 170 KB, acima do limite de 128 KiB por argumento. Mergeado às 13:01.
13:02	CLEAN-030 implementação (13 min): `qa/process.ps1` com a cópia exata do `Stop-AndWait`.
13:15	CLEAN-030 revisão (32 min). O primeiro gate falhou num teste Rust fora do diff; a repetição passou. Mergeado às 13:46.
13:47	CLEAN-032 implementação (15 min), dois pares vermelho/verde.
14:02	CLEAN-032 revisão 1: **limite de 40 min** às 14:42, com o `cargo test` ainda linkando. O driver marca `blocked` e abre o PR #11.
14:45	Foreman salva `recovery/20261004-1442/clean-032`, volta o ticket a `to-review` (`b53df37`) e relança com `-ReviewMinutes 60` (pid 14168).
14:46	CLEAN-032 revisão 2 (60 min): rebase sobre a sessão, gate verde, parada real do qemu medida por sonda própria. Mergeado às 15:46; “Nothing runnable”.

2 Métricas por estágio

As 7 linhas de `.scratch/run-log.md` do run. "Custo log" é o que o driver gravou; "Custo calc." aplica o preço de `dc530fb` (fast = 2 vezes `gpt-6.1-sol`: $4,00/M entrada, $0,40/M em cache, $20,00/M saída) à soma dos `turn.completed` do `.txt` de cada estágio; na última linha, os dois coincidem.

Fim	Ticket	Estágio	Min	Entrada	Cache	Saída	Custo log	Custo calc.	Desfecho
12:28	CLEAN-027	impl.	18	6,0 M	98 %	13 k	?	3,04	to-review
13:01	CLEAN-027	rev.	33	9,1 M	98 %	44 k	?	5,15	mergeado
13:15	CLEAN-030	impl.	13	4,6 M	98 %	10 k	?	2,42	to-review
13:46	CLEAN-030	rev.	32	9,0 M	98 %	39 k	?	5,00	mergeado
14:02	CLEAN-032	impl.	15	3,2 M	97 %	12 k	?	1,79	to-review
14:42	CLEAN-032	rev.	40	?	?	?	?	?	limite, blocked
15:46	CLEAN-032	rev.	60	12,1 M	97 %	78 k	7,571	7,57	mergeado
Total			211	43,9 M	97,8 %	197 k	7,57	24,97	6 com uso



Onde foi o custo. Por ticket, calculado: CLEAN-027 $8,18, CLEAN-030 $7,42, CLEAN-032 $9,36 mais a revisão perdida. A revisão custou 71 % do run ($17,72 de $24,97): 9–12 M tokens de entrada cada, quase tudo cache relido a cada turno de QA. A perda foi de tempo: os 40 min da primeira revisão do CLEAN-032, cujo trabalho (comentários reordenados e o CLEAN-033) sobreviveu na branch.

3 Comparação

Contra o sol normal, no mesmo repositório e na mesma lineup de esforço (`gpt-6.1-sol high` implementa, `gpt-6.1-sol max` revisa), todas as linhas de `run-log.md`; e contra o run anterior (`2026-10-03-sweatshop-astra-medium-sol-max.pdf`).

	sol normal (SynchroNice)	sol-fast, 04/10	astra/sol, 03–04/10
Implementações até `to-review`	11	3	13
Minutos por implementação, mediana	24	15	11
Custo por implementação, média	$1,36	$2,42 (calc.)	$4,49
Revisões concluídas	35	3	13
Minutos por revisão concluída, mediana	28	33	35
Custo por revisão, média	$1,79	$5,91 (calc.)	$2,03
Reaberturas no run	—	0 de 3	3 de 10
Minutos de estágio por ticket mergeado	—	70	74

Ressalvas, nesta ordem de peso: **concorrência** — a partir de 12:43 dois outros drivers sol-fast rodavam na mesma máquina, e o gate deste repositório compila Rust; só a implementação do CLEAN-027 rodou sozinha (18 min); **amostra** — 3 estágios de cada tipo; **tickets diferentes** —

os do sol normal incluem backend e Android, estes são scripts do kit. O preço por estágio subiu mais que o dobro do tier na revisão (3,3 vezes) porque as revisões deste run leram mais tokens: QA no emulador com sonda própria e, no CLEAN-032, o gate inteiro duas vezes.

Nos outros dois repositórios, no mesmo dia e mesma lineup, as revisões sol-fast levaram 5–17 min (ClassyCall e PhysiSyst não sobem emulador): o tempo da revisão aqui é do kit, não do modelo.

4 Atribuição das reaberturas

Nenhuma rodada reaberta e nenhum conserto da revisão em commit próprio: os commits das três revisões são relatório de QA, reordenação de comentários e o ticket CLEAN-033. Nada a rotular; `.scratch/reopen-attribution.md` não mudou. Descobertas pós-aprovação: as revisões dos PRs de sessão #10 e #11 são só o Copilot sem cota; nenhum defeito confirmado.

O que é do stage 3. Sem *drip-feeding* nem *churn*. A revisão do CLEAN-032 achou, por leitura, um caminho de falha fora dos cinco critérios (repetição do `down` depois de uma parada que falhou perde a identidade do processo) e abriu o CLEAN-033 em vez de reabrir, como a recomendação 3 do relatório anterior pedia.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre os cinco repositórios desta máquina com `.scratch/run-log.md` (SynchroNice, ClassyCall, PhysiSyst, SIGAA-ME, slip), depois de registrar as intervenções. Cumulativo.

Implementer	Stage runs	To review	Failed	Asked	Median min to review	Cost
fable	5	5	0	0	3m	?
sonnet	121	75	31	15	7m	$10.53 (4/121 priced)
gpt-6-luna	23	11	10	2	26m	?
gpt-6-sol	6	5	1	0	17m	?
gpt-5.6-sol	5	4	1	0	17m	?
gpt-6-astra	18	11	6	1	8m	?
sonnet-5 xhigh	11	6	2	3	8m	$18.09 (11/11 priced)
gpt-6.1-sol high	38	33	0	5	8m	$29.32 (38/38 priced)
gpt-6-astra low	2	2	0	0	30m	$19.03 (2/2 priced)
gpt-6.1-sol max	3	1	2	0	17m	$1.44 (1/3 priced)
sonnet-5.5 xhigh	9	8	1	0	25m	$35.54 (9/9 priced)
sonnet-5.5 high	16	15	1	0	7m	$28.15 (16/16 priced)
gpt-6-astra medium	57	47	1	9	10m	$162.72 (57/57 priced)
gpt-6.1-sol-fast high	11	10	0	1	13m	$4.44 (6/11 priced)
gpt-6.1-sol-fast max	8	6	0	2	13m	$5.27 (4/8 priced)
opus-5.5	35	31	4	0	6m	$0.72 (1/35 priced)
opus-5.5 high	2	2	0	0	9m	$2.31 (2/2 priced)

Implementador	Revisor	Reviews	Reab.	Taxa	Por S2	Taxa S2	Sem rót.	S2 na rev.
fable	fable	4	1	25%	0	≥0%	1	0
?	opus	4	0	0%	0	0%	0	0
sonnet	opus	68	20	29%	1	≥1%	19	0
gpt-6-luna	gpt-6-sol	11	7	64%	0	≥0%	7	0
gpt-6-sol	gpt-5.6-sol	5	4	80%	0	≥0%	4	0
gpt-5.6-sol	gpt-6-astra	4	3	75%	0	≥0%	3	0
gpt-6-astra	gpt-5.6-sol	11	5	45%	0	≥0%	5	0
sonnet-5 xhigh	opus-5.5 xhigh	5	0	0%	0	0%	0	0
gpt-6.1-sol high	gpt-6.1-sol max	32	8	25%	7	22%	0	0
gpt-6-astra low	gpt-6.1-sol max	2	1	50%	1	50%	0	0
gpt-6.1-sol max	gpt-6.1-sol max	1	1	100%	1	100%	0	0
sonnet-5.5 xhigh	gpt-6.1-sol max	7	3	43%	3	43%	0	0
sonnet-5.5 high	gpt-6.1-sol max	12	3	25%	3	25%	0	0
gpt-6-astra medium	gpt-6.1-sol max	37	7	19%	6	16%	0	1
gpt-6.1-sol-fast high	gpt-6.1-sol-fast max	10	1	10%	0	≥0%	1	0
gpt-6.1-sol-fast max	gpt-6.1-sol-fast max	6	3	50%	0	≥0%	3	0
opus-5.5	fable-5.1	30	1	3%	0	≥0%	1	0
opus-5.5 high	fable-5.1 high	1	0	0%	0	0%	0	0
opus-5.5 high	opus-5.5 xhigh	1	0	0%	0	0%	0	0
sonnet-5.5 high	opus-5.5 xhigh	3	0	0%	0	0%	0	3
sonnet-5.5 xhigh	opus-5.5 xhigh	1	0	0%	0	0%	0	0
gpt-6-astra medium	gpt-6-astra xhigh	10	1	10%	1	10%	0	0
sonnet	fable	1	0	0%	0	0%	0	0

Implementer → Reviewer	Rounds	S2 explicit code	S2 explicit test	S2 implicit	S1	S3 noise
sonnet → opus	1	1	1	0	0	0
gpt-6.1-sol high → gpt-6.1-sol max	9	5	0	9	1	0
gpt-6-astra low → gpt-6.1-sol max	1	2	0	1	0	0
gpt-6.1-sol max → gpt-6.1-sol max	1	4	0	1	0	0
sonnet-5.5 xhigh → gpt-6.1-sol max	3	7	0	3	2	0
sonnet-5.5 high → gpt-6.1-sol max	3	5	0	2	3	0
gpt-6-astra medium → gpt-6.1-sol max	8	11	1	4	1	0
sonnet-5.5 high → opus-5.5 xhigh	3	1	2	0	0	0
gpt-6-astra medium → gpt-6-astra xhigh	1	1	0	0	0	0

Cobertura de evidência (saída da mesma execução): 68 achados registrados por *ticket-review*; "earlier review miss" 0 de 10 conhecidos e "review-induced churn" 0 de 10. Do fim do turno à saída do processo: 163,3 s em 113 estágios medidos, 549 sem medida. Intervenções registradas: 2 resgates humanos, 6 recuperações automáticas, 10 decisões do proxy (este run: 3 decisões e 1 recuperação, primeiro registro do SynchroNice).

O que mudou desde o relatório de 03/10.

- **Duas linhas novas:** `gpt-6.1-sol-fast high` (11 estágios) e `gpt-6.1-sol-fast max` (8), três de cada vindas deste run, o resto de ClassyCall e PhysiSyst no mesmo dia. Custo parcial (6/11 e 4/8 com preço) porque o preço do fast entrou no meio do dia.
- **Par novo** `gpt-6.1-sol-fast high` → `gpt-6.1-sol-fast max`: 10 revisões, 1 reaberta (10 %), sem rótulo (é de outro repositório). **Menos de 10 revisões rotuladas: anedota.** O par `sol-fast max` → `sol-fast max` tem 6 revisões e 3 reaberturas sem rótulo, também de outro repositório.
- `gpt-6-astra medium`: de 55 para 57 estágios e de 35 para 37 revisões sob sol max (outro repositório); taxa S2 de 17 para 16 %.
- Intervenções: proxy de 7 para 10 e recuperações de 5 para 6, deste run.

Fast contra normal, mesmo revisor? Não dá ainda: o revisor do par fast também é fast, então `sol-fast high` só se compara com `sol high` (25 % de reabertura, 22 % S2, 32 revisões) quando as reaberturas do fast estiverem rotuladas e passarem de 10.

6 Observações sobre os modelos

gpt-6.1-sol-fast (high), implementação

- **Disciplina igual à do sol normal:** testes em commit próprio antes do conserto nos dois tickets que os pediam; no CLEAN-032, dois pares vermelho/verde, um por critério. Gate completo antes de `to-review`.
- **Sandbox:** o `-TestsOnly` dentro do sandbox do Codex tomou `Access denied` nos testes do PC e rede negada no Gradle; o modelo rodou o gate completo fora do sandbox e anotou a diferença no ticket, sem esconder.
- **Desvio leve repetido:** no CLEAN-027 e no CLEAN-030 a passagem a `to-review` saiu num commit separado do último commit de código; as duas revisões anotaram como desvio de processo sem efeito.

gpt-6.1-sol-fast (max), revisão

- **Reproduz de verdade:** `wifi-off` real com o dump do emulador (170 KB) no CLEAN-027; no CLEAN-032, sonda própria que guardou o handle do qemu antes do `down` real e conferiu, no retorno, processo morto e nenhum listener em 5554/5555.
- **Contorna a infraestrutura sem afrouxar:** na retomada o `up` real abortou (sem presença em 30 s) e o pareamento foi recusado pela tela bloqueada; a revisão registrou `pairExit=1` como falha de infraestrutura e não usou a retentativa como prova do critério 5.
- **Teste instável tratado como tal:** no CLEAN-030, o primeiro gate falhou num teste Rust fora do diff; a revisão repetiu o gate inteiro, guardou as duas saídas e não reabriu.
- **Longa por natureza:** 32–60 min com QA no emulador; o modo fast não encurtou nada disso.

7 Integração com o Codex, o Claude e o driver

- **Token `fast` no driver** (`b18746c`): a linha do modelo ganha `-fast`, o Codex recebe `-config service_tier=fast`, e o Claude o recusa. O preço (`dc530fb`, outra sessão) entrou com o run já rodando: as 6 primeiras linhas ficaram `?`. O humano chegou a duvidar que o tier estivesse ativo; a outra sessão confirmou que estava.
- **Concorrência entre drivers:** três sweatshops na mesma máquina disputaram CPU; o `cargo test` do gate do SynchroNice é o mais pesado deles e foi o que estourou o limite.
- **Limite de revisão:** 40 min (padrão para `max`) não cabe uma revisão com kit + gate completo sob carga; 60 min coube com 6 s de folga.
- **Erro do foreman:** o primeiro commit da recuperação caiu no `main` local (o driver deixa o repositório lá ao parar): `f03289d`, só um comentário no CLEAN-032, sem push. O classificador de permissões negou o reset e o revert; fica para o humano.
- **Teste Rust instável:** `exclusao_durante_upload_que_falha_descarta_item_e_retry` abortou com o erro 10053 do Windows (`tests/server.rs:570`) no primeiro gate do CLEAN-030; passou na repetição.

8 Recomendações

1. **Mergear o PR #11** antes do próximo run.
2. **Triar o CLEAN-033** (retentativa do `down` depois de uma parada que falhou).
3. **Fast só no stage 2, se em algum.** A implementação ganhou tempo; a revisão, presa ao gate e ao emulador, não ganhou e custou 3,3 vezes mais. Para medir de verdade: um run com a máquina livre e 10 ou mais estágios de cada lado.
4. **Não rodar sweatshops em paralelo nesta máquina** quando o objetivo for medir tempo, ou subir `-ReviewMinutes` para 75 nos tickets do kit.

5. **Preencher o custo das 6 linhas ??** Os valores da coluna "Custo calc." saem da fórmula do driver sobre os mesmos logs; o foreman não os gravou no `run-log.md` sem o humano decidir.
6. **Ticket para o teste Rust instável** (erro 10053), da mesma família do upload concorrente que forçou `RUST_TEST_THREADS=1` no SYN-030.
7. **Kit: `up` com tela bloqueada.** O `up` real da retomada não achou presença em 30 s e o pareamento foi recusado pela tela bloqueada do emulador; vale um ticket de triagem para o `up` acordar e desbloquear o AVD antes de parear.
8. **`main` local:** descartar `f03289d` (`git branch -f main 70534d5`).

9 Decisões do proxy

- **CLEAN-027:** "aceito (normal, Review: agent); wait_wifi nunca passa o dump como argumento, dumpsys com erro falha sem retentativa, vermelho comportamental no harness (printf embutido desligado e printf falso com limite de 128 KiB por argumento) e wifi-off real no emulador como verificação — o bash do harness tem printf embutido, então só emulando o mksh do aparelho o teste reproduz o defeito; checagem estática do script testaria a forma, não o comportamento."
- **CLEAN-030:** "aceito como refatoração pequena (normal, Review: agent); Stop-AndWait num único qa/process.ps1 carregado por up/down/pc via $PSScriptRoot, mesmos prazos e erros, sem teste novo — os wrappers já se chamam por $PSScriptRoot, não há autocontenção a preservar, e a política já precisou de duas correções no CLEAN-026; teste de 'não define cópia' seria de organização interna, que a spec exclui."
- **CLEAN-032:** "aceito (normal, Review: agent, sem Blocked by); antes do emu kill o down guarda o dono do listener da porta do serial, espera até 30 s ele sair depois que o serial some do adb e senão aplica Stop-AndWait, e os testes nunca usam a 5554 — o critério 5 do SYN-025 pede down sem qemu e o up logo após o down é o uso do loop; reusa o Stop-AndWait existente, então não depende do CLEAN-030."

10 Débito humano

Nenhuma linha `Débito humano:` neste run: os três tickets são do kit e foram verificados por teste e no emulador. Sem aparelho: o passo do Redmi pós-run não rodou.